

Lecture 14

强大数定律 中心极限定理

Bertsekas & Tsitsiklis Ch5 5.4 5.5

何书元 Ch5.4 B

郑翔宇

ZHENGXIANGYU@TSINGHUA.EDU.CN



课程回顾

► 概率空间 $(\Omega, \mathcal{F}, \mathbb{P})$

- 定义(样本空间、事件域、概率测度), 概率公理 (非负、归一、可列可加)
- 事件的条件概率 (三个计算公式), 事件的独立性

► 随机变量 $X := X(\omega)$

- 随机变量定义; 随机变量的函数; 随机向量; 随机向量的函数
- 离散型 (PMF) & 连续型 (PDF)、概率分布函数 (CDF)
- 条件分布: 条件CDF, 条件PMF/PDF; 随机变量的独立性.
- 母函数(生成函数): 概率母函数PGF, 矩母函数MGF, 特征函数C.F.

► 随机变量的数字特征

- 数学期望、方差、p分位数 (特例. 中位数)、协方差 与 相关系数
- 条件分布的数字特征: 条件期望, 条件方差; 条件期望 $E[X|Y]$ 是 Y 的函数, 也是随机变量

► 随机变量极限理论



目录

- ▶ 大数定律
Law of Large Number (LLN)
 - 弱大数定律
 - 强大数定律
- ▶ 中心极限定理
Central Limit Theorem (CLT)



再理解「弱大数定律」和「依概率收敛」

► $\frac{1}{n} \sum_{k=1}^n X_k$ 依概率收敛至 μ : 用 $\frac{\sum_{k=1}^n X_k}{n}$ 估计 μ , 出现任意小偏差的概率总是趋于0的




■ 出现偏差: $\left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| > \varepsilon$ 【事件】

■ 出现偏差的概率: $P\left(\left| \frac{1}{n} \sum_{k=1}^n X_k - \mu \right| > \varepsilon\right) =: p_n(\varepsilon)$ 【事件的概率】

■ 出现偏差的概率趋于0: $p_n(\varepsilon) \rightarrow 0$ as $n \rightarrow \infty$ 【数列的极限是0】

■ 出现任意小偏差的概率趋于0: $\forall \varepsilon > 0, p_n(\varepsilon) \rightarrow 0$ as $n \rightarrow \infty$ 【任取 $\varepsilon > 0$, 数列极限是0】

► 具体的例子: 考虑 $X_k \sim i.i.d B(1, 0.5)$



「依概率收敛」的「一般形式」

Lec12. 定理2.1(Weak law of large numbers, WLLN)

设 $\{X_n\}$ 是独立同分布的随机变量序列, 且 $\text{Var}(X_1) < \infty$, 则

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{p} E[X_1].$$

$$\forall \varepsilon > 0, P(|\frac{1}{n} \sum_{k=1}^n X_k - E[X_1]| > \varepsilon) \rightarrow 0 \text{ as } n \rightarrow \infty.$$

Lec12. 定义2.1 依概率收敛

设 $\{X_n\}$ 是随机变量序列, X 为一随机变量, 如果对 $\forall \varepsilon > 0$,


$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0,$$

则称 $\{X_n\}$ 依概率收敛于 X , 记作 $\lim_{n \rightarrow \infty} X_n \xrightarrow{p} X$.



如何定义「更强」的收敛方式

- ▶ 随机变量 $X = X(\omega)$ 是从 样本空间 到 实数 $\mathbb{R}$ 的映射
- ▶ 随机变量是一个函数



大数定律
LLN

中心极限定理
CLT

- ▶ 随机变量序列 $\{X_n\}$ 是一个函数序列
- ▶ 如何描述：函数 X_n “收敛” 到 函数 X ?

$$\forall \omega \in \Omega, X_n(\omega) \rightarrow X(\omega) \text{ as } n \rightarrow \infty$$

$\{\omega \mid X_n(\omega) \rightarrow X(\omega) \text{ as } n \rightarrow \infty\}$ 的概率是1



以概率1收敛 (几乎必然收敛)

► 定义1.1 几乎必然收敛

设 $\{X_n\}$ 是随机变量序列, X 为一随机变量, 如果

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1,$$

则称 $\{X_n\}$ 几乎必然收敛于 X , 记作 $\lim_{n \rightarrow \infty} X_n \xrightarrow{a.s.} X$ (又称 **以概率1 收敛**).

大数定律
LLN

► 如何直观理解「几乎必然收敛」和「依概率收敛」的差异

中心极限定理
CLT

► 几乎必然收敛 确实是更强的收敛吗? 如果 $\lim_{n \rightarrow \infty} X_n \xrightarrow{a.s.} X$, 能否证明 $\lim_{n \rightarrow \infty} X_n \xrightarrow{p} X$



直观：几乎必然收敛 vs. 依概率收敛

依概率收敛

$$\lim_{n \rightarrow \infty} X_n \xrightarrow{p} X: \text{对 } \forall \varepsilon > 0, \\ \lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

几乎必然收敛

$$\lim_{n \rightarrow \infty} X_n \xrightarrow{a.s.} X \\ P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

大数定律
LLN

► 如何理解「几乎必然收敛」和「依概率收敛」的差异？



ω : 稻粒是否合格, 随机变量(合格与否1/0)
 $X_n(\omega)$: 经过n次改良后稻粒是否合格
 $X(\omega) \equiv 1$: 全部合格对应随机变量恒等于1

清华大学统计与数据科学系



依概率收敛:

不合格的数量 $\rightarrow 0$
(宏观汇总)

中心极限定理
CLT



几乎必然收敛:

关注每个稻粒的命运
(微观检查)



例1.1

样本空间 $\Omega = [0,1]$, 事件域 $\mathcal{F} = \mathcal{B} \cap [0,1]$, 概率P取几何概率 (概率=长度)
对于任意的正整数 $n \geq 1, 1 \leq k \leq 2^{n-1}$, 定义:

$$X_{2^{n-1}+k-1}(\omega) = \begin{cases} 1, & \omega \in \left[\frac{k-1}{2^{n-1}}, \frac{k}{2^{n-1}}\right) \\ 0, & \text{else} \end{cases}$$







以及 $X(\omega) \equiv 0$, 简记 $X := X(\omega), X_n := X_n(\omega)$.

大数定律
LLN中心极限定理
CLT

- A $\lim_{n \rightarrow \infty} X_n \xrightarrow{p} 0$
- B $\lim_{n \rightarrow \infty} X_n \xrightarrow{a.s.} 0$
- C A 和 B 都不对



举例： 对于 $n \geq 1, 1 \leq k \leq 2^{n-1}$, $X_{2^{n-1}+k-1}(\omega) = \begin{cases} 1, & \omega \in \left[\frac{k-1}{2^{n-1}}, \frac{k}{2^{n-1}}\right) \\ 0, & \text{else} \end{cases}$



大数定律
LLN

中心极限定理
CLT



举例：依概率收敛 但不是 几乎必然收敛

► **例1.1** 定义 $X_{2^{n-1}+k-1}(\omega) = \begin{cases} 1, & \omega \in \left[\frac{k-1}{2^{n-1}}, \frac{k}{2^{n-1}}\right) \\ 0 & , \text{否则} \end{cases} \quad 1 \leq k \leq 2^{n-1}$
 以及 $X(\omega) \equiv 0$, 简记 $X := X(\omega), X_n := X_n(\omega)$.

大数定律
LLN

中心极限定理
CLT

$$n = 1, \quad X_1(\omega) = I(\omega \in [0, 1))$$

$$n = 2, \quad X_2(\omega) = I(\omega \in [0, 1/2))$$

$$n = 3, \quad X_3(\omega) = I(\omega \in [1/2, 1))$$

$$n = 4, \quad X_4(\omega) = I(\omega \in [0, 1/4))$$

$$n = 5, \quad X_5(\omega) = I(\omega \in [1/4, 2/4))$$

$$n = 6, \quad X_6(\omega) = I(\omega \in [2/4, 3/4))$$

$$n = 7, \quad X_7(\omega) = I(\omega \in [3/4, 1))$$

... ..



证明: 如果 几乎必然收敛, 是否 依概率收敛?

► 定理1.1

设 $\{X_n\}$ 是随机变量序列, X 为一随机变量,

$$\text{如果 } \lim_{n \rightarrow \infty} X_n \xrightarrow{a.s.} X, \text{ 则 } \lim_{n \rightarrow \infty} X_n \xrightarrow{p} X$$

大数定律
LLN

► 证明:

已知条件

定义事件 $C := \{\omega \mid \lim_{n \rightarrow \infty} X_n(\omega) \rightarrow X(\omega)\}$, 根据定义 a.s. 收敛 说明 $P(C) = 1$

证明目标

定义事件 $B_n := \{\omega \mid |X_n(\omega) - X(\omega)| \leq \varepsilon\}$, 依概率收敛 等价于 $\forall \varepsilon > 0, P(B_n) \rightarrow 1 \text{ as } n \rightarrow \infty$

中心极限定理
CLT

by 数列收敛的定义: $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ 说明 $\forall \varepsilon > 0$, 存在某个 k , $\forall n \geq k, |X_n(\omega) - X(\omega)| \leq \varepsilon$. 定义

因此 $\lim_{n \rightarrow \infty} X_n(\omega) = X(\omega)$ 说明 $\omega \in \bigcup_{k=1}^{\infty} \bigcap_{n=k}^{\infty} B_n$

因此 $\omega \in C \Rightarrow \omega \in \bigcup_{k=1}^{\infty} \bigcap_{n=k}^{\infty} B_n$, 因此 $C \subset \bigcup_{k=1}^{\infty} \bigcap_{n=k}^{\infty} B_n$, $P(\bigcup_{k=1}^{\infty} \bigcap_{n=k}^{\infty} B_n) = 1$

因此 $\lim_{n \rightarrow \infty} P(B_n) = 1$



强大数定律：均值 几乎必然收敛至 期望

► 定理1.2 (Strong law of large numbers, SLLN)

设 $\{X_k\}$ 是独立同分布的随机变量序列, 若 $E|X_1| < \infty$ (期望存在且有限) 则

$$\frac{1}{n} \sum_{k=1}^n X_k \xrightarrow{a.s.} E[X_1] \text{ 几乎处处收敛.}$$

大数定律
LLN

注1: 定理陈述参考 何书元 chap 5.4 定理 4.3 (给出了四阶矩有限时的证明)

中心极限定理
CLT

注2: 强大数定律定律说明 「频率 几乎必然收敛至 概率」

- 令 $Y_n = \frac{1}{n} \sum_{i=1}^n I(X_k \in A)$, 则 $Y_n \xrightarrow{a.s.} P(A)$

- 则 $Y_n \xrightarrow{a.s.} P(A)$ 说明,

事件 $\{\omega | Y_n(\omega) \rightarrow P(A)\}$ 发生的概率是1

```
def cal_sample_mean_path(seed, p, n):
    """
    固定随机数种子, 生成独立同分布的 $X_1, \dots, X_n$ ,
    返回每一步的样本均值序列。
    """
    random.seed(seed)
    samples, sample_mean_path = [], []
    for i in range(1, n+1):
        x = np.random.binomial(1, p)
        samples.append(x)
        current_mean = sum(samples) / i
        sample_mean_path.append(current_mean)
    return sample_mean_path
```



应用：蒙特卡洛方法（或随机模拟方法）



► 强大数定律：任何一条路径都收敛

➔ 任何一次实现，当n足够大时，样本均值都趋近于总体均值

► 例：计算 π (Buffon 投针)

$$\hat{\pi} = 4 \cdot \bar{I}$$

大数定律
LLN



中心极限定理
CLT



应用 蒙特卡洛方法 求 积分

► 例1.2 (Monte Carlo 蒙特卡洛)

需估计某复杂有界函数 $f(x)$ 在区间 $[a, b]$ 上的积分 $\int_a^b f(x)dx$.


大数定律
LLN

► 解. 从 A 中随机抽取 n 个点 $(X_1, Y_1), \dots, (X_n, Y_n)$. 用 I_j 表示 (X_j, Y_j) 落入 B 与否. 则


以概率1有
$$\frac{1}{n} \sum_{j=1}^n I_j \rightarrow E(I_j) = \mathbb{P}(I_j = 1) = \frac{\int_a^b f(x)dx}{c(b-a)}$$

中心极限定理
CLT

$$\int_a^b f(x)dx \approx c(b-a) \frac{1}{n} \sum_{j=1}^n I_j.$$



- ▶ 大数定律: $\frac{1}{n} \sum_{k=1}^n X_k \rightarrow E[X_1]$ as $n \rightarrow \infty$
- ▶ 对于有限的 n , $\frac{1}{n} \sum_{k=1}^n X_k$ 还是「随机变量」
- ▶ 能否更精细地刻画 $\frac{1}{n} \sum_{k=1}^n X_k$ 的分布?
 - $E\left[\frac{1}{n} \sum_{k=1}^n X_k\right]$
 - $\text{var}\left[\frac{1}{n} \sum_{k=1}^n X_k\right]$




► 独立同分布的随机变量

$$\square E \left[\frac{1}{n} \sum_{k=1}^n X_k \right] = \mu$$

$$\square \text{var} \left[\frac{1}{n} \sum_{k=1}^n X_k \right] = \frac{1}{n} \sigma^2$$

► $\frac{1}{n} \sum_{k=1}^n X_k$ 的「标准化」

$$Z_n = \frac{\frac{1}{n} \sum_{k=1}^n X_k - \mu}{\sqrt{\frac{1}{n} \sigma^2}} = \frac{\sqrt{n}}{\sigma} \times \left(\frac{1}{n} \sum_{k=1}^n X_k - \mu \right)$$



► 独立同分布的随机变量

$$\square E\left[\frac{1}{n}\sum_{k=1}^n X_k\right] = \mu$$


$$\square \text{var}\left[\frac{1}{n}\sum_{k=1}^n X_k\right] = \frac{1}{n}\sigma^2$$

► $\frac{1}{n}\sum_{k=1}^n X_k$ 的「标准化」

$$Z_n = \frac{\frac{1}{n}\sum_{k=1}^n X_k - \mu}{\sqrt{\frac{1}{n}\sigma^2}} = \frac{\sqrt{n}}{\sigma} \times \left(\frac{1}{n}\sum_{k=1}^n X_k - \mu \right)$$

► 标准正态分布 密度函数

$$\phi(0) = \frac{1}{\sqrt{2\pi}} e^0 \approx 0.4$$



► 独立同分布的随机变量

$$\square E \left[\frac{1}{n} \sum_{k=1}^n X_k \right] = \mu$$

$$\square \text{var} \left[\frac{1}{n} \sum_{k=1}^n X_k \right] = \frac{1}{n} \sigma^2$$

► $\frac{1}{n} \sum_{k=1}^n X_k$ 的「标准化」


$$Z_n = \frac{\frac{1}{n} \sum_{k=1}^n X_k - \mu}{\sqrt{\frac{1}{n} \sigma^2}} = \frac{\sqrt{n}}{\sigma} \times \left(\frac{1}{n} \sum_{k=1}^n X_k - \mu \right)$$

► 概率分布列(区间的概率) → 概率密度:

$$f_n(z)\delta \approx P(z \leq Z_n \leq z + \delta)$$

$$f_n(z) \approx \frac{1}{\delta} P(z \leq Z_n \leq z + \delta)$$

因此 Z_n 的「概率分布」的极限是
标准正态分布 $Z \sim N(0,1)$ 的「概率分布」



大数定律
LLN

中心极限定理
CLT

中心极限定理



中心极限定理--内容概览

► 基本定理

大数定律
LLN

► 应用举例

► 细致讨论

中心极限定理
CLT

□ 离散化修正

□ 适用条件



大数定律
LLN

中心极限定理
CLT

基本定理



定义「依分布收敛」 (收敛模式)

► 定义 2.1 (convergence in distribution)

设 Y_n, Y 的分布函数分别为 $F_n(y), F(y)$. 如果在 $F(y)$ 的连续点 y , 有

$$\lim_{n \rightarrow \infty} F_n(y) = F(y),$$


则称 Y_n 依分布收敛到 Y (convergence in distribution), 记作 $Y_n \xrightarrow{d} Y$,
或者称 F_n 弱收敛到 F (weak convergence), 记作 $F_n \xrightarrow{w} F$.

大数定律
LLN

中心极限定理
CLT

因此 Z_n 的「概率分布」的极限
是
标准正态分布 $Z \sim N(0,1)$ 的「概率分布」

-- 链接 “离散” 与 “连续”：概率分布函数



中心极限定理

定理 2.1 (Lindeberg - Lévy 中心极限定理)

设 $\{X_n\}$ 是独立同分布的随机变量序列，其期望为 μ ，方差为 $\sigma^2 < \infty$ ，记 $S_n = X_1 + \cdots + X_n$ ，则

$$\frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} N(0,1).$$

大数定律
LLN

中心极限定理
CLT

n 充分大时，提供近似分布

$$\begin{aligned} S_n &\approx N(E(S_n), \text{Var}(S_n)) \\ &\approx N(n\mu, n\sigma^2) \end{aligned}$$




发展理论
解释现象

► 解读：大量独立同分布的随机因素的叠加~正态分布.




回忆：二项分布 & 泊松分布

25



图：二项分布的折线图，其中 $p = 0.5$.



图：Poisson 分布的概率分布列折线图.



定理证明思路:

$$\frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}} = \frac{1}{\sqrt{n}} \sum_{k=1}^n \frac{(X_k - \mu)}{\sigma} = \frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$$

已知: $\{Y_k\}$ 独立同分布. $E[Y_k] = 0, \text{Var}(Y_k) = 1$.

往证: $\frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k \xrightarrow{d} N(0,1)$.



$\frac{1}{\sqrt{n}} \sum_{k=1}^n Y_k$ 的特征函数 $\rightarrow e^{-t^2/2}, n \rightarrow \infty$.

$$= \left[\phi_Y \left(\frac{t}{\sqrt{n}} \right) \right]^n$$

$$= \left(1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right)^n$$

$$\rightarrow e^{-t^2/2} \quad \lim_{n \rightarrow \infty} \left(1 + \frac{a_n}{n} \right)^n = e^a \text{ when } a_n \rightarrow a$$

► Lec13. 延伸定理 1.3 [连续性定理]

如果设随机变量序列 X_n 的分布函数 $F_n(x)$ 对应的特征函数为 $\phi_n(t)$, 如果

$$\lim_{n \rightarrow \infty} \phi_n(t) \rightarrow \phi(t)$$

且 $\phi(t)$ 在 0 点连续, 则 $\phi(t)$ 为特征函数, $F_n(x)$ 收敛于 $\phi(t)$ 对应的分布函数 $F(x)$

大数定律
LLN

$$\mathbb{P} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i \leq x \right) \text{ v.s. } \mathbb{P}(Y_i \leq x)$$

中心极限定理
CLT

$$\phi_Y(t) = E[e^{itY_1}]$$

Lec13. 定理1.3 特征函数的泰勒展开

如果 $E(X^2) < \infty$, 则

$$\phi(t) = 1 + it E(X) - \frac{1}{2} t^2 E(X^2) + o(t^2)$$



中心极限定理----各种表达形式

► 定理 2.1 (Central limit theorem, CLT)

设 $\{X_n\}$ 是独立同分布的随机变量序列, 其期望为 μ , 方差为 $\sigma^2 < \infty$.

记 $S_n = X_1 + \cdots + X_n$, 则

$$\frac{S_n - E(S_n)}{\sqrt{\text{Var}(S_n)}} \xrightarrow{d} N(0,1).$$

记 $M_n = (X_1 + \cdots + X_n)/n$, 则

$$\frac{M_n - E(M_n)}{\sqrt{\text{Var}(M_n)}} \xrightarrow{d} N(0,1).$$

或:

$$\frac{1}{\sqrt{n}} \frac{M_n - \mu}{\sqrt{\text{Var}(X_1)}} \xrightarrow{d} N(0,1).$$

大数定律
LLN

中心极限定理
CLT



小结



小结

► 知识点

✓ 大数定律

- ✓ 强弱大数定律的区别：收敛方式不同 (依概率 vs. 几乎必然)；条件不同
- ✓ 应用：蒙特卡洛方法

✓ 中心极限定理

- ✓ 基本定理内容与证明；依分布收敛的定义；正态分布的地位；
- ✓ 能基于极限定理解决的简单的应用问题 (e.g. 确定样本量)

► 方法

- ✓ 用连续分布函数近似表达离散分布函数时，需适当修正；
- ✓ 利用特征函数的极限确定随机变量极限的分布。



谢谢大家！

