

概率论

目录

一、考试范围	2
二、课程知识框架	2
三、各章详解	2
第 1 章条件期望与条件方差	2
本章总览	2
(一) 条件期望的定义与计算 必背	3
(二) 条件期望的基本性质 重点	5
(三) 重期望法则 (Law of Total Expectation) 高频	6
(四) 条件期望与预测 重点	7
(五) 条件方差 重点	7
本章小结	8
本章小结	13
第 2 章生成函数与矩母函数	14
本章总览	14
一) 概率母函数 (PGF) 的定义与计算 必背	14
二) 概率母函数的基本性质 高频	15
三) 常见分布的概率母函数 必背	17
四) 随机向量的概率母函数 重点	18
五) 从 PGF 到 MGF 的过渡 重点	19
本章小结	19
矩母函数 高频	20
特征函数 重点	23
本章小结	24
第 3 章特征函数与大数定律	25
特征函数 重点	25
本章总览	27
依概率收敛 必背	27
弱大数定律 (WLLN) 及其证明 必背	28
不等式: 切比雪夫不等式与马尔可夫不等式 高频	29

大数定律条件的放宽 重点	31
几乎必然收敛 (以概率 1 收敛) 与强大数定律 重点	32
本章小结	33
强大数定律 (SLLN) 与收敛模式辨析 重点	36
依分布收敛与中心极限定理 必背	36
本章小结	38
本章知识关系	38
本章核心结论	38
必背公式	39
记忆 一句话记忆	39

> 本笔记由 [复习资料整理 Agent] 自动生成：入口无损读取全部原始资料，出口按考试优先原则整理。

一、考试范围

（资料中未显式标注考试范围，以下为自动识别的章节范围，请以教师最终通知为准）

- 条件期望与条件方差
- 生成函数与矩母函数
- 特征函数与大数定律

二、课程知识框架

概率论

- 条件期望与条件方差
- 生成函数与矩母函数
- 特征函数与大数定律

三、各章详解

第 1 章条件期望与条件方差

本章总览

本章聚焦于条件期望与条件方差两大核心概念，是连接条件分布与数字特征的桥梁。

- 核心问题：
 1. 如何计算给定 $Y = y$ 时 X 的平均水平？（条件期望的定义与计算）
 2. 如何将条件期望视为随机变量，并利用它来简化期望与方差的计算？（重期望法则、全方差公式）
 3. 条件期望在预测问题中有何应用？
- 高频考点排序：重期望法则 > 条件期望的计算（尤其是联合正态）> 全方差公式 > 条件期望的线性性质。
- 方法清单：
 - 计算：条件期望需先求出条件分布（离散型求条件分布列，连续型求条件密度），再按定义积分或求和。
 - 证明：重期望法则和全方差公式的证明，核心是“先条件再边缘”的积分次序交换。
 - 预测/应用：利用重期望法则求解含有分支结构的期望问题（如密室逃脱问题）。

(一) 条件期望的定义与计算 **必背**##### 1. 条件期望 $E(X|Y=y)$ 的定义 **必背**

- **定义**：在给定事件 $\{Y=y\}$ 发生的条件下， X 的条件分布的数学期望。

- **离散型**：若 $\sum_i |x_i| P(X=x_i|Y=y) < \infty$ ，则

$$E(X|Y=y) = \sum_i x_i P(X=x_i|Y=y)$$

- **连续型**：若 $\int_{-\infty}^{\infty} |x| f_{X|Y}(x|y) dx < \infty$ ，则

$$E(X|Y=y) = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx$$

- **一般情形**： $E(X|Y=y)$ 是条件分布函数 $F(x|Y=y)$ 所对应的数学期望。[Lec11_2026_0513.pdf P11-P13]

- **原理与推导**：其本质与无条件期望完全一致，只是将概率测度/密度替换为“条件”版本。先求条件分布，再求期望。

- **解题步骤**：计算 $E(X|Y=y)$

1. **确定条件分布**：对于给定的 $Y=y$ ，求出 X 的条件分布列 $P(X=x_i|Y=y)$ （离散型）或条件密度函数 $f_{X|Y}(x|y)$ （连续型）。
2. **代入定义计算**：根据上一步得到的条件分布，通过求和（离散）或积分（连续）计算出期望值。结果是一个关于 y 的函数。

- **易错点**

- **混淆条件与非条件**：计算 $E(X|Y=y)$ 时，必须使用条件分布 $f_{X|Y}(x|y)$ ，而非边缘分布 $f_X(x)$ 或联合分布 $f(x,y)$ 。
- **忽视定义域**：条件期望 $E(X|Y=y)$ 只在 $f_Y(y) > 0$ 的 y 上有定义。
- **概念对比**：

概念	定义	输入	输出
期望 $E(X)$	边缘分布下的平均值	–	一个常数
条件期望 $E(X Y=y)$	条件分布下的平均值	一个具体的数值 y	一个关于 y 的函数值
条件期望（随机变量） $E(X Y)$	将 y 替换为随机变量 Y	随机变量 Y	一个随机变量

P23 例 3（续），计算二元正态分布的条件期望。[Lec11_2026_0513.pdf P23]

题目

设 $(X, Y) \sim N(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$ ，求 $E(X|Y=y)$ 。

思路

二元正态分布的条件分布仍为正态分布。利用已知条件分布 $X|Y = y \sim N(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2), (1 - \rho^2)\sigma_1^2)$ ，其期望即为条件期望。

解答

已知在 $Y = y$ 条件下， X 服从正态分布，其数学期望为：

$$E(X|Y = y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2)$$

结果是一个关于 y 的线性函数。

技巧

牢记结论：对于联合正态分布，条件期望 $E(X | Y = y)$ 是 y 的线性函数，且系数可通过 ρ 和标准差之比直接写出。若 X, Y 标准化（均值为 0，方差为 1），则 $E(X | Y = y) = \rho y$ 。

2. 将条件期望视为随机变量 $E(X|Y)$ **重点**

- **定义**：令 $m(y) = E(X|Y = y)$ ，则将函数 $m(\cdot)$ 作用于随机变量 Y 所得到的新随机变量 $m(Y)$ 记为 $E(X|Y)$ 。[Lec11_2026_0513.pdf P19]

$$E(X|Y) = m(Y), \quad \text{其中 } m(y) = E(X|Y = y)$$

- **原理与推导**：这是一个从“函数”到“随机变量”的推广。因为 Y 是随机变量，所以当我们具体的取值 y 替换为随机变量 Y 本身时，条件期望就从一个确定的值变成了一个随机变量，其随机性完全来源于 Y 。
- **易错点**： $E(X|Y)$ 是关于 Y 的函数，所以它是一个随机变量，有期望和方差。而 $E(X|Y = y)$ 是一个关于 y 的函数，给定 y 时它是一个常数。
- **例题**：

P20 例 1（续），计算泊松分布的条件期望随机变量。[Lec11_2026_0513.pdf P20]

题目

设 X, Y 独立同分布于泊松分布 $\mathcal{P}(\lambda)$ ，求 $E(X + Y|X)$ 。

思路

先计算给定 $X = x$ 下的条件期望 $E(X + Y|X = x)$ ，得到一个关于 x 的表达式，再将 x 替换为随机变量 X 。

解答

$$E(X + Y|X = x) = E(x + Y|X = x) = x + E(Y|X = x)$$

由于 X, Y 独立, $E(Y|X = x) = E(Y) = \lambda$ 。因此, $E(X + Y|X = x) = x + \lambda$ 。将 x 替换为 X , 得到 $E(X + Y|X) = X + \lambda$ 。

技巧

计算 $E(g(X, Y)|X)$ 时, 可将 X 视为常数 x , 利用“提取已知变量”的性质 $E(h(X)g(Y)|X = x) = h(x)E(g(Y)|X = x)$ 来简化。

(二) 条件期望的基本性质 **重点**

- **定义**: 条件期望继承了无条件期望的所有线性性质, 并有一些特殊性质。
- **原理与推导**: 条件期望是关于条件分布的期望, 而条件分布本身是一种概率测度, 因此期望的线性性质自然得到保持。
- **性质清单**: 假定以下期望均存在。[Lec11_2026_0513.pdf P14-P15]
 1. **常数提取/自映射**: $E(h(Y)g(X)|Y) = h(Y)E(g(X)|Y)$ 。特别地, $E(X | X = x) = x$ 。
 2. **线性性**: $E(aX + bY | Z = z) = aE(X | Z = z) + bE(Y | Z = z)$ 。
 3. **独立性与退化**: 若 X 和 Y 独立, 则 $E(X | Y = y) = E(X)$ 。即在独立条件下, Y 的信息对预测 X 的平均水平无帮助, 条件期望退化为无条件期望。
- **易错点**
 - $E(h(Y)g(X)|Y) = h(Y)E(g(X)|Y)$ 中, $h(Y)$ 像一个常数被提取出来, 但必须注意提取的条件是随机变量 Y 本身被给定。若条件是另一个变量 $Z = z$, 则不能直接提取关于 Y 的函数。
 - 概念对比:

	普通期望	条件期望
常数	$E(c) = c$	$E(X X = x) = x$
线性	$E(aX + bY) = aE(X) + bE(Y)$	$E(aX + bY Z) = aE(X Z) + bE(Y Z)$
独立时的行为	$E(XY) = E(X)E(Y)$ (不相关)	$E(X Y) = E(X)$

P16 例 1, 利用线性性质计算。[Lec11_2026_0513.pdf P16]

题目

设 X, Y 独立同分布于 $\mathcal{P}(\lambda)$, 求 $E(X + Y | X = x)$ 。

思路

直接应用条件期望的线性性质和对已知变量的提取性质。

解答

$$E(X + Y | X = x) = E(X | X = x) + E(Y | X = x)$$

由性质 $E(X | X = x) = x$ 。由独立性, $E(Y | X = x) = E(Y) = \lambda$ 。所以, $E(X + Y | X = x) = x + \lambda$ 。

技巧

这是计算此类问题的标准“套路”：将已知条件的变量视作常数，利用线性性拆开，再分别利用映射性质和独立性质化简。

(三) 重期望法则 (Law of Total Expectation) 高频

- **定义** (定理 1.2): 设 X, Y 是随机变量, 且 $E(X)$ 存在, 则

$$E(E(X|Y)) = E(X)$$

[Lec11_2026_0513.pdf P27]

- **原理与推导**: 无条件期望是先对 X 和 Y 的联合分布求积分, 而条件期望是先固定 Y 对 X 的条件分布求积分, 再对 Y 的边缘分布求积分。这等价于交换积分次序。

– 离散型证明:

$$\begin{aligned} E(E(X|Y)) &= \sum_y E(X|Y=y)P_Y(y) \\ &= \sum_y \left(\sum_x xP_{X|Y}(x|y) \right) P_Y(y) \\ &= \sum_x x \left(\sum_y P_{X,Y}(x,y) \right) = \sum_x xP_X(x) = E(X) \end{aligned}$$

- **解题步骤**: 何时使用重期望法则?

1. **分情况求期望**: 问题包含多个阶段 (如密室逃脱), 或变量的分布依赖于另一个随机变量。(见例 4)
2. **计算无条件期望**: 直接计算 $E(X)$ 困难, 但计算条件期望 $E(X|Y)$ 和 Y 的分布相对容易。此时可通过 $E(X) = E[E(X|Y)]$ 来求解。

- **易错点**: 误用为 $E(E(X|Y)) = E(X|Y)$ 。正确理解是: 里层的 $E(X|Y)$ 是随机变量, 外层的 $E(\cdot)$ 是对这个随机变量求无条件期望, 结果是一个常数 $E(X)$ 。

- **例题**:

真题例 4, 密室逃脱问题, 考察重期望法则的应用。[Lec11_2026_0513.pdf P28]**题目**

一个密室有三个门。选择门 1 需走 3 小时到达出口；门 2 需走 5 小时返回原地；门 3 需走 7 小时返回原地。玩家每次等可能地随机选一个门。求到达出口所需平均时间。

思路

设 X 为到达出口总时间, Y 为第一次选的门。利用重期望法则 $E(X) = E[E(X|Y)]$, 通过条件于第一次选择来建立方程。

解答

设第一次选择的门为 Y 。由重期望法则: $E(X) = \sum_{i=1}^3 E(X | Y = i)P(Y = i)$ 而 $P(Y = i) = 1/3$ 。下面计算各条件下的期望: - 若 $Y = 1$: 直接到达出口, $E(X | Y = 1) = 3$ 。 - 若 $Y = 2$: 走 5 小时回到原点, 之后的过程与重新开始无异, 因此 $E(X | Y = 2) = 5 + E(X)$ 。 - 若 $Y = 3$: 走 7 小时回到原点, 同理 $E(X | Y = 3) = 7 + E(X)$ 。代入公式得:

$$E(X) = \frac{1}{3} \cdot 3 + \frac{1}{3} \cdot (5 + E(X)) + \frac{1}{3} \cdot (7 + E(X))$$

解得方程: $3E(X) = 3 + 5 + 7 + 2E(X) \Rightarrow E(X) = 15$ 小时。

技巧

当过程具有“无记忆性”或“回到原点”的重置特性时, 重期望法则能建立关于期望的方程, 是求解此类递归型期望问题的关键。

(四) 条件期望与预测 重点

- **定义**: 在许多实际问题中, 我们希望通过一个变量 Y 预测另一个变量 X 。条件期望 $E(X|Y)$ 提供了在均方误差意义下的**最优预测**。
- **原理与推导**: 可以证明, 所有基于 Y 的函数 $g(Y)$ 中, 使得均方预测误差 $E[(X - g(Y))^2]$ 最小的函数正是 $g(Y) = E(X | Y)$ 。因此, 条件期望 $E(X | Y = y)$ 是在给定 $Y = y$ 的信息下, 对 X 的最优点预测。[Lec11_2026_0513.pdf P9]
- **举例**: 若 (X, Y) 是联合正态分布, 已知 $E(X|Y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(Y - \mu_2)$, 则这个关于 Y 的线性函数就是预测 X 的最优函数。它恰好是最优线性预测。

(五) 条件方差 重点

- **定义**: 在给定 $Y = y$ 的条件下, X 的条件方差定义为

$$\text{Var}(X|Y = y) = E[(X - E(X|Y = y))^2|Y = y]$$

简化计算公式同样适用:

$$\text{Var}(X|Y = y) = E(X^2|Y = y) - [E(X|Y = y)]^2$$

将其中 y 替换为随机变量 Y ，即得到条件方差随机变量 $\text{Var}(X|Y)$ 。[Lec11_2026_0513.pdf P5]

- 全方差公式 (Law of Total Variance) 必背：

$$\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$$

- 原理与推导：该公式将 X 的总变异性分解为两部分：
 - 组内方差 (Within-group variance): $E[\text{Var}(X|Y)]$ ，衡量了在 Y 的每组内部 X 的平均变异性。
 - 组间方差 (Between-group variance): $\text{Var}(E[X|Y])$ ，衡量了不同 Y 组的均值之间的变异性。
- 解题步骤：何时使用全方差公式？
 - 直接计算 $\text{Var}(X)$ 复杂，但条件方差 $\text{Var}(X|Y)$ 和条件期望 $E(X|Y)$ 易于处理时。
 - 在分层抽样、混合模型等需要分解变异来源的问题中。
- 易错点：牢记公式，其形式为 $\text{Var}(X) = E(\text{条件方差}) + \text{Var}(\text{条件期望})$ ，不要与重期望法则混淆。
- 例题：

真题 P18，计算条件期望。[Lec11_2026_0513.pdf P18]

题目

设 $X \sim U(0, 1)$ ， $Y = 1_{\{X \geq 0.5\}}$ 。求 $E[X|Y = y]$ 。

思路

先求条件分布，再计算数学期望。

解答

当 $Y = 0$ （即 $X < 0.5$ ）时， $X|Y = 0 \sim U(0, 0.5)$ 。当 $Y = 1$ （即 $X \geq 0.5$ ）时， $X|Y = 1 \sim U(0.5, 1)$ 。因此，条件期望为分段函数：
$$E(X|Y=y) = \begin{cases} \frac{0 + 0.5}{2} = 0.25, & y=0 \\ \frac{0.5 + 1}{2} = 0.75, & y=1 \end{cases}$$

技巧

对于由示性函数定义的条件，条件分布通常就是原分布在某个区间上的截断分布。此题中，均匀分布的截断依然是均匀分布。

本章小结

- 知识关系：条件期望是条件分布的数字特征，其本身从 $Y = y$ 的函数被推广为随机变量 $E(X|Y)$ 。重期望法则和全方差公式则建立了条件数字特征与无条件数字特征之间的桥梁。

• 核心结论:

1. $E(X|Y)$ 是预测 X 的均方误差最优函数。
2. $E(E(X|Y)) = E(X)$ 。
3. $\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$ 。

• 必背公式:

– 重期望法则:

$$E(X) = E[E(X | Y)]$$

– 全方差公式:

$$\text{Var}(X) = E[\text{Var}(X | Y)] + \text{Var}(E[X | Y])$$

– 条件期望简化计算:

$$\text{Var}(X | Y) = E(X^2 | Y) - [E(X | Y)]^2$$

- **记忆**: 条件期望求期望用重期望, 条件方差求方差用全方差。前者是“均值的均值等于总均值”, 后者是“总方差 = 组内方差均值 + 组间方差”。

核心问题: 如何利用已知信息 (条件) 更精准地描述随机变量的平均水平 (条件期望) 和波动程度 (条件方差)? 条件期望为何被誉为 “最佳预测”? **高频考点排序**:

1. 重期望法则的应用 (包括随机个独立同分布随机变量之和的期望计算)
2. 全方差法则 (EVVE 公式) 的计算与应用
3. 条件期望作为均方误差最小预测的定理及其证明思路
4. 条件期望与条件方差的定义与性质 **方法清单**: 重期望法则 (全期望公式)、全方差法则 (EVVE 公式)、“加一项减一项” 技巧 (用于证明最优预测性质)、利用条件的分布特征直接计算条件期望与方差。

1. 最佳预测定理

- **定义**: 在均方误差 (MSE) 损失函数下, 对于随机变量 Y , 基于随机变量 X 的最优预测函数 $\hat{Y} = g(X)$ 就是条件期望 $m(X) = \mathbb{E}[Y|X]$ 。它使得预测的均方误差达到最小。
- **原理与推导**: **定理 1.3**: 设 $\mathbb{E}[Y^2] < \infty$, $m(X) = \mathbb{E}[Y|X]$, 则对任何实函数 $g(x)$, 有

$$\mathbb{E}[(Y - m(X))^2] \leq \mathbb{E}[(Y - g(X))^2]$$

等号成立当且仅当 $g(X) = m(X)$ a.s. (几乎处处成立)。

证明思路 (“加一项、减一项” 技巧): 将预测误差分解为两部分:

1. 将项 $g(X)$ 进行拆分:

$$Y - g(X) = (Y - m(X)) + (m(X) - g(X))$$

2. 两边平方后取期望：

$$\mathbb{E}[(Y - g(X))^2] = \mathbb{E}[(Y - m(X))^2] + \mathbb{E}[(m(X) - g(X))^2] + 2\mathbb{E}[(Y - m(X))(m(X) - g(X))]$$

3. 核心是证明交叉项为零。利用重期望法则：

$$\mathbb{E}[(Y - m(X))(m(X) - g(X))] = \mathbb{E}\{\mathbb{E}[(Y - m(X))(m(X) - g(X))|X]\}$$

4. 在内层条件期望中， $(m(X) - g(X))$ 是 X 的函数，可以提出：

$$= \mathbb{E}\{(m(X) - g(X)) \cdot \mathbb{E}[Y - m(X)|X]\}$$

5. 根据条件期望定义， $\mathbb{E}[Y - m(X)|X] = \mathbb{E}[Y|X] - m(X) = 0$ 。因此交叉项为 0。

6. 最终得到：

$$\mathbb{E}[(Y - g(X))^2] = \underbrace{\mathbb{E}[(Y - m(X))^2]}_{\text{最小可能误差 (MSE)}} + \underbrace{\mathbb{E}[(m(X) - g(X))^2]}_{\geq 0} \geq \mathbb{E}[(Y - m(X))^2]$$

该式表明，任何函数 $g(X)$ 的 MSE 都不会优于 $m(X)$ ，且只有当 $g(X) = m(X)$ 时才能取到下界。[Lec11_2026_0513.pdf P32-33]

• **易错点：**

对比项	条 件 期 望 $\mathbb{E}[m(X) = X]$ $\mathbb{E}[Y]$	无 条 件 期 望 $\mu = \mathbb{E}[Y]$
信息量	利用了 X 的信息	未利用任何其他变量信息
预测精度 (MSE)	$\mathbb{E}[(Y - m(X))^2]$ (更小)	$\text{Var}(Y) = \mathbb{E}[(Y - \mu)^2]$ (更大)
函数形式	是 X 的一般函数 (随机变量)	是一个常数
关系	$m(X)$ 是 Y 在 MSE 下的最佳预测； μ 是常数预测中的最佳预测。	当 $g(X) = c$ 时，最佳常数 $c^* = \mathbb{E}[Y]$ 。

特别地，当 $g(X) = \mathbb{E}[Y]$ (记为常数 μ) 时，定理 1.3 给出了一个极为重要的方差分解关系：

$$\mathbb{E}[(Y - \mu)^2] = \mathbb{E}[(Y - m(X))^2] + \mathbb{E}[(m(X) - \mu)^2]$$

即 $\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|X)] + \text{Var}(\mathbb{E}[Y|X])$ ，这是下一节全方差法则的直接推论。[Lec11_2026_0513.pdf P34]

(自编) 最佳预测定理的直接应用, 验证条件期望的预测优于线性预测。

题目

设 (X, Y) 服从标准二元正态分布, 即 $\mu_X = \mu_Y = 0$, $\sigma_X = \sigma_Y = 1$, $\rho = 0.8$ 。已知最优预测为 $m(X) = E(Y|X) = 0.8X$ 。现在考虑一个简单的线性预测 $g(X) = X$ (即直接猜测 $Y = X$)。请计算并比较 $m(X)$ 和 $g(X)$ 的均方预测误差。

思路

由于 $m(X)$ 是最佳预测, 其 MSE 应严格小于 $g(X)$ 的 MSE。可利用定理中的关键等式 $E[(Y - g(X))^2] = E[(Y - m(X))^2] + E[(m(X) - g(X))^2]$ 直接求解。

解答

首先, 计算最优预测 $m(X)$ 的 MSE (即不可约误差): $\text{Var}(Y|X) = \sigma_Y^2(1 - \rho^2) = 1 - 0.64 = 0.36$ 。因此 $E[(Y - m(X))^2] = E[\text{Var}(Y|X)] = 0.36$ 。然后, 计算 $g(X)$ 与 $m(X)$ 的偏离: $E[(m(X) - g(X))^2] = E[(0.8X - X)^2] = E[0.04X^2] = 0.04\text{Var}(X) = 0.04$ 。利用等式, $E[(Y - g(X))^2] = 0.36 + 0.04 = 0.40$ 。可见, 最优预测 $m(X) = 0.8X$ 的 MSE 为 0.36, 而简单预测 $g(X) = X$ 的 MSE 为 0.40, 条件期望确实更优。

技巧

此结论有两个用处: 通过比较 MSE 判断预测函数的优劣; 如果想计算一个预测函数的 MSE, 可以拆成“最优的 MSE”+“预测函数与最优预测的差距”两部分来计算, 这在联合正态情形下非常方便。

1. 条件方差的定义与计算 必背

- **定义**: 给定 X 的条件下, Y 的条件方差定义为在条件分布下, Y 与其条件期望之差的平方的条件期望。

$$\text{Var}(Y|X) := E[(Y - E[Y|X])^2 | X]$$

在 $X = x$ 处的具体值为:

$$\text{Var}(Y|X = x) := E[(Y - E[Y|X = x])^2 | X = x]$$

- **原理与推导**: 条件方差本质上是基于条件分布 $P_x(\cdot)$ 计算出的普通方差。固定 $X = x$ 后, $\text{Var}(Y|X = x)$ 是一个确定的数; 而作为随机变量函数的 $\text{Var}(Y|X)$ 则是一个随机变量, 其取值由 X 决定。它度量了在已知 X 后 Y 的剩余波动。[Lec11_2026_0513.pdf P36]
- **解题步骤** 计算 $\text{Var}(Y|X = x)$:
 1. **确定条件分布**: 找出给定 $X = x$ 时 Y 的分布形式 (如正态、均匀等) 及其参数。
 2. **识别参数或直接计算**:
 - 若条件分布是常见分布, 则 $\text{Var}(Y|X = x)$ 就是该分布的方差。
 - 否则, 按定义计算: $\text{Var}(Y|X = x) = E[Y^2|X = x] - (E[Y|X = x])^2$ 。

3. 还原为随机变量：将第 2 步结果中的 x 替换为 X ，即得到 $\text{Var}(Y|X)$ 。

- **易错点**： $\text{Var}(Y|X)$ 是 X 的函数，也是一个随机变量，拥有自身的期望和方差。而 $\text{Var}(Y|X = x)$ 是一个常数。

2. 全方差法则 (EVVE 公式) **必背**

- **定义**：将总方差拆解为“组内方差的均值”与“组间均值的方差”之和的公式。定理 2.1 (全方差法则 / EVVE 公式)：

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|X)] + \text{Var}(\mathbb{E}[Y|X])$$

- **原理与推导**：该公式是定理 1.3 的直接推论。如前所述，取 $g(X) = \mathbb{E}[Y] = \mu$ ，则有：

$$\text{Var}(Y) = \mathbb{E}[(Y - \mu)^2] = \mathbb{E}[(Y - m(X))^2] + \mathbb{E}[(m(X) - \mu)^2]$$

剖析右边两项：

- **第一项** $\mathbb{E}[(Y - m(X))^2]$ ：利用重期望法则， $\mathbb{E}[(Y - m(X))^2] = \mathbb{E}\{\mathbb{E}[(Y - m(X))^2|X]\} = \mathbb{E}[\text{Var}(Y|X)]$ 。它代表了不可由 X 解释的、纯粹的“噪声”或组内波动。
- **第二项** $\mathbb{E}[(m(X) - \mu)^2]$ ：注意 $m(X) = \mathbb{E}[Y|X]$ 是 X 的函数，且期望 $\mathbb{E}[m(X)] = \mu$ 。因此这一项正是 $\mathbb{E}[Y|X]$ 的方差 $\text{Var}(\mathbb{E}[Y|X])$ 。它代表了由于 X 的不同而引起的 Y 的平均水平的波动。[Lec11_2026_0513.pdf P37-38]

- **解题步骤** 应用全方差法则计算 $\text{Var}(Y)$ ：

1. 识别分组变量 X 。
2. 计算条件期望 $\mathbb{E}[Y|X]$ 和条件方差 $\text{Var}(Y|X)$ （均为 X 的函数）。
3. 计算 $\mathbb{E}[\text{Var}(Y|X)]$ （组内方差的均值）。
4. 计算 $\text{Var}(\mathbb{E}[Y|X])$ （组间均值的方差），利用 $\text{Var}(Z) = \mathbb{E}[Z^2] - (\mathbb{E}[Z])^2$ 。
5. 将步骤 3 和 4 的结果相加。

- **例题**：

(课件例 6)

题目

考虑一个连续随机变量 X ，其概率密度函数如下图（由两个均匀分布组成：一半概率在 $[0, 1]$ 上，一半概率在 $[1, 3]$ 上）。请计算其方差。[Lec11_2026_0513.pdf P39-40]

思路

X 的分布可看作两个均匀分布的混合。我们可以引入一个分类变量 Y 来指示 X 来自哪一个分布，然后用全方差法则计算总方差。

解答

1. 定义辅助随机变量 $Y = I(X > 1)$, 则 $Y \sim B(1, 1/2)$ 。2. 计算条件期望与条件方差: - 给定 $Y = 0$ ($X \leq 1$), $X \sim U[0, 1]$ 。 $\mathbb{E}[X|Y = 0] = 1/2$, $\text{Var}(X|Y = 0) = 1/12$ 。 - 给定 $Y = 1$ ($X > 1$), $X \sim U[1, 3]$ 。 $\mathbb{E}[X|Y = 1] = 2$, $\text{Var}(X|Y = 1) = (3 - 1)^2/12 = 4/12$ 。3. 计算 $\mathbb{E}[\text{Var}(X|Y)]$ (组内方差均值):

$$\mathbb{E}[\text{Var}(X|Y)] = \frac{1}{2} \times \frac{1}{12} + \frac{1}{2} \times \frac{4}{12} = \frac{5}{24}$$

4. 计算 $\text{Var}(\mathbb{E}[X|Y])$ (组间均值方差): 首先计算 $\mathbb{E}[\mathbb{E}[X|Y]] = \frac{1}{2} \times \frac{1}{2} + \frac{1}{2} \times 2 = 1.25 = \frac{5}{4}$ 。然后计算 $\mathbb{E}[(\mathbb{E}[X|Y])^2] = \frac{1}{2} \times (\frac{1}{2})^2 + \frac{1}{2} \times 2^2 = \frac{17}{8}$ 。故 $\text{Var}(\mathbb{E}[X|Y]) = \frac{17}{8} - (\frac{5}{4})^2 = \frac{17}{8} - \frac{25}{16} = \frac{9}{16}$ 。

5. 相加得总方差:

$$\text{Var}(X) = \frac{5}{24} + \frac{9}{16} = \frac{10}{48} + \frac{27}{48} = \frac{37}{48}$$

技巧

对于混合分布或分段函数分布, 引入一个指示变量 (示性变量) 来 “贴上标签”, 再用全期望/全方差公式是标准套路。

本章小结

- **知识关系:** 条件期望与条件方差是概率论中承上启下的核心内容。重期望法则与全方差法则建立起了条件概率、条件期望与无条件期望、方差之间的桥梁。这两个法则也是后续课程 (如数理统计、随机过程、计量经济学、机器学习) 中处理层次化数据、理解方差分解、推导回归模型性质的基石。其中, 条件期望的 “最佳预测” 性质直接奠定了回归分析的理论基础。

- **核心结论:**

1. **重期望法则:** 无条件期望等于条件期望的期望。 $\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]]$ 。
2. **最佳预测:** 在均方误差意义下, 基于 X 对 Y 的最佳预测函数是 $\mathbb{E}[Y|X]$ 。
3. **全方差法则:** 总方差 = 组内方差的期望 + 组间均值的方差。 $\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|X)] + \text{Var}(\mathbb{E}[Y|X])$ 。

- **必背公式:**

1. 重期望法则:

$$\mathbb{E}[Y] = \mathbb{E}[\mathbb{E}[Y|X]]$$

2. 随机个独立同分布随机变量之和的期望:

$$\mathbb{E}\left[\sum_{i=1}^Y X_i\right] = \mathbb{E}[X]\mathbb{E}[Y] \quad (\text{其中 } X_i \text{ i.i.d. 且与 } Y \text{ 独立})$$

3. 最佳预测不等式:

$$\mathbb{E}[(Y - \mathbb{E}[Y|X])^2] \leq \mathbb{E}[(Y - g(X))^2]$$

4. 条件方差定义:

$$\text{Var}(Y|X) = \mathbb{E}[(Y - \mathbb{E}[Y|X])^2|X]$$

5. 全方差法则 (EVVE):

$$\text{Var}(Y) = \mathbb{E}[\text{Var}(Y|X)] + \text{Var}(\mathbb{E}[Y|X])$$

- **记忆**: 期望是均值的均值, 方差是均方差加方差均。预测之王是条件期望, 方差拆解组内加组间。

第 2 章生成函数与矩母函数

本章总览

本章引入一类研究随机变量分布与数字特征的有力工具: **概率母函数(PGF)**与**矩母函数(MGF)**。核心问题是: 如何利用一个函数“打包”随机变量的所有概率信息或矩信息? 高频考点包括: PGF 的定义与收敛域、利用 PGF 求概率和数字特征(期望、方差)、独立随机变量和的 PGF、以及常见分布(二项、泊松、几何)的 PGF 推导与应用。核心方法为: 通过求导获取概率/矩, 以及利用独立性和 PGF 判定和分布的类型。

一) 概率母函数 (PGF) 的定义与计算 **必背**

定义 设 X 是取非负整数值的随机变量, 其分布列为 $p_j = \mathbb{P}(X = j)$, $j = 0, 1, 2, \dots$ 。称

$$g(s) = \mathbb{E}[s^X] = \sum_{j=0}^{\infty} s^j \mathbb{P}(X = j), \quad s \in [-1, 1]$$

为 X 的概率母函数 (Probability Generating Function, PGF), 约定 $0^0 = 1$ 。[Lec12_2026_0520.pdf P9]

原理与推导 PGF 可视为序列 $\{p_j\}$ 的一个幂级数表示。由于 $\sum |p_j| = 1$, 该级数在 $|s| \leq 1$ 时绝对收敛, 因此定义在 $[-1, 1]$ 上是良好的。PGF 唯一决定了随机变量的分布列。

解题步骤 计算离散随机变量 PGF 的一般步骤:

1. **确定分布列**: 写出 $p_j = \mathbb{P}(X = j)$ 的表达式。
2. **代入定义**: 计算 $g(s) = \sum_j p_j s^j$ 。
3. **化简级数**: 利用等比数列求和、二项式定理或指数函数的幂级数展开等技巧, 将求和式化为封闭形式 (初等函数)。

易错点

- **定义域混淆**: PGF 的定义域是 $[-1, 1]$, 级数在此区间内绝对收敛。忘记此前提可能导致误用性质。
- **非负整值要求**: PGF 只对取非负整数值的随机变量定义。对于可取负数或非整数的随机变量, 需引入矩母函数或特征函数。

- 0^0 约定: 计算 $g(0)$ 时, $g(0) = \sum s^j \mathbb{P}(X = j)|_{s=0} = \mathbb{P}(X = 0)$, 这与 $0^0 = 1$ 的约定一致。

易混概念对比	概率母函数 (PGF)	矩母函数 (MGF)
定义	$\mathbb{E}[s^X]$	$\mathbb{E}[e^{tX}]$
适用变量	仅适用于非负整数值随机变量	适用于一般随机变量
主要作用	唯一决定分布列, 便于处理独立和	唯一决定分布, 便于计算各阶矩

例题

题目

设 X 是取非负整值的随机变量, $g(s)$ 是其概率母函数, 求 $g(1)$ 和 $g'(1)$ 的值。
[Lec12_2026_0520.pdf P9-P10]

思路

直接从 PGF 定义和绝对收敛性质出发, 通过代入 $s = 1$ 和逐项求导解决。

解答

1. 代入定义: $g(s) = \sum_{j=0}^{\infty} s^j \mathbb{P}(X = j)$ 。2. 当 $s = 1$ 时, $g(1) = \sum_{j=0}^{\infty} 1^j \mathbb{P}(X = j) = \sum \mathbb{P}(X = j) = 1$ 。3. 对定义逐项求导: $g'(s) = \sum_{j=1}^{\infty} j s^{j-1} \mathbb{P}(X = j)$ 。4. 代入 $s = 1$: $g'(1) = \sum_{j=1}^{\infty} j \cdot 1^{j-1} \mathbb{P}(X = j) = \sum j \mathbb{P}(X = j) = \mathbb{E}[X]$ 。

技巧

务必记住 PGF 在 1 处的函数值和一阶导数值对应着概率总和与期望, 这是串联 PGF 与数字特征的桥梁。

二) 概率母函数的基本性质 高频

定义 设 $g(s)$ 为 X 的 PGF, $g^{(k)}(s)$ 是其 k 阶导数。

原理与推导 根据幂级数的性质, PGF 在 $(-1, 1)$ 内无限次可微, 并且可以逐项求导。利用此解析性质, 可以方便地提取概率和矩信息。

1. 求概率与期望:

- 由 $g(s) = \sum p_j s^j$, 令 $s = 1$ 得 $g(1) = 1$ 。
- 逐项求导得 $g'(s) = \sum j p_j s^{j-1}$, 令 $s = 1$ 得 $g'(1) = \mathbb{E}[X]$ 。[Lec12_2026_0520.pdf P11]

2. 提取分布列:

- 将 $g(s)$ 泰勒展开, s^j 的系数即 $\mathbb{P}(X = j)$, 即 $\mathbb{P}(X = k) = \frac{g^{(k)}(0)}{k!}$ 。这保证了 PGF 与分布列是相互唯一决定的。[Lec12_2026_0520.pdf P12]

3. 独立随机变量和:

- 若 $X_1, \dots, X_n$ 相互独立, 其 PGF 分别为 $g_1(s), \dots, g_n(s)$, 则其和 $Y = X_1 + \dots + X_n$ 的 PGF 为 $g_Y(s) = \prod_{i=1}^n g_i(s)$ 。这是因为 $\mathbb{E}[s^{\sum X_i}] = \mathbb{E}[\prod s^{X_i}] \stackrel{\text{ind.}}{=} \prod \mathbb{E}[s^{X_i}]$ 。[Lec12_2026_0520.pdf P13]

4. 计算方差:

- 对 $g(s)$ 求二阶导: $g''(s) = \sum j(j-1)p_j s^{j-2}$ 。
- 令 $s = 1$: $g''(1) = \mathbb{E}[X(X-1)] = \mathbb{E}[X^2] - \mathbb{E}[X]$ 。
- 因此, 方差可表示为:

$$\text{Var}(X) = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = g''(1) + g'(1) - [g'(1)]^2$$

[Lec12_2026_0520.pdf P15]

解题步骤

- **步骤 1: 求期望:** 对 PGF 求导, 代入 $s = 1$ 。
- **步骤 2: 求方差:** 先求 $g'(1)$ 和 $g''(1)$, 代入公式 $\text{Var}(X) = g''(1) + g'(1) - [g'(1)]^2$ 。
- **步骤 3: 求独立和的分布:** 分别写出各分量的 PGF, 相乘, 再通过泰勒展开或幂级数识别法确定和变量的分布类型及参数。

易错点

- **求导不彻底:** 计算方差时, 必须正确使用 $g''(1) = \mathbb{E}[X(X-1)]$, 而非直接得到 $\mathbb{E}[X^2]$ 。忘记加回 $\mathbb{E}[X]$ 项是常见错误。
- **独立性前提:** 独立随机变量和的 PGF 等于各自 PGF 的乘积, 此性质必须以独立性为前提, 对非独立变量不成立。
- **泰勒展开与幂级数:** 从乘积 PGF 还原分布列时, 可利用泰勒展开公式 $p_k = g^{(k)}(0)/k!$, 或直接尝试将乘积累化为已知分布的标准幂级数形式。后者通常更快捷。

例题

题目

设 $X_1, X_2, \dots, X_n$ 是相互独立的随机变量, $X_i \sim \mathcal{P}(\lambda_i)$ 。求 $Y = X_1 + X_2 + \dots + X_n$ 的分布。[Lec12_2026_0520.pdf P18, P19]

思路

利用独立和的 PGF 性质和泊松分布的 PGF, 计算出 Y 的 PGF, 再将其与标准分布的 PGF 对比, 反推出分布类型。

解答

1. 已知 $X_i \sim \mathcal{P}(\lambda_i)$, 其 PGF 为 $g_{X_i}(s) = e^{\lambda_i(s-1)}$ 。(见下方例 1.2) 2. 由于各 X_i 相互独立, 应用性质 3, Y 的 PGF 为各 PGF 之积:

$$g_Y(s) = \prod_{i=1}^n g_{X_i}(s) = \prod_{i=1}^n e^{\lambda_i(s-1)} = e^{(\sum_{i=1}^n \lambda_i)(s-1)}$$

3. 观察 $g_Y(s)$ 的形式, 它恰为参数 $\lambda = \sum \lambda_i$ 的泊松分布的 PGF。4. 因此, 由 PGF 与分布的唯一确定性, 知 $Y \sim \mathcal{P}(\sum_{i=1}^n \lambda_i)$ 。

技巧

独立泊松分布之和仍为泊松分布, 参数为各参数之和。记住“PGF 相乘, 参数相加”。

三) 常见分布的概率母函数 必背

1. 二项分布 $B(n, p)$

• PGF 推导:

$$g(s) = \mathbb{E}[s^X] = \sum_{j=0}^n s^j \binom{n}{j} p^j q^{n-j} = \sum_{j=0}^n \binom{n}{j} (sp)^j q^{n-j} = (q + sp)^n$$

其中 $q = 1 - p$ 。[Lec12_2026_0520.pdf P16]

• 应用: 若 $X_i \sim B(n_i, p)$ 且相互独立, 则 $\sum X_i \sim B(\sum n_i, p)$ 。

2. 泊松分布 $\mathcal{P}(\lambda)$

• PGF 推导:

$$g(s) = \sum_{k=0}^{\infty} s^k \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{(s\lambda)^k}{k!} = e^{-\lambda} \cdot e^{s\lambda} = e^{\lambda(s-1)}$$

[Lec12_2026_0520.pdf P17]

• 应用: 多个独立泊松变量之和仍为泊松变量, 参数相加。

3. 几何分布 $G(p)$

• PGF 推导:

$$g(s) = \sum_{k=1}^{\infty} s^k p q^{k-1} = \frac{sp}{1 - sq}$$

其中 $q = 1 - p$, 收敛域 $|sq| < 1$ 。[Lec12_2026_0520.pdf P20]

• 应用: m 个独立同分布的几何分布变量之和 (S_m) 服从帕斯卡分布。其 PGF 为 $g_{S_m}(s) = \left(\frac{sp}{1-sq}\right)^m$ 。将 PGF 泰勒展开或求导, 可得其分布列为:

$$\mathbb{P}(S_m = k) = \binom{k-1}{m-1} p^m q^{k-m}, \quad k = m, m+1, \dots$$

[Lec12_2026_0520.pdf P20-P21]

四) 随机向量的概率母函数 **重点**

定义 设 X, Y 是二维取非负整数值随机向量, 其联合分布列为 $p_{ik} = \mathbb{P}(X = i, Y = k), i, k = 0, 1, 2, \dots$ 。称

$$g(s, t) = \mathbb{E}[s^X t^Y] = \sum_{i=0}^{\infty} \sum_{k=0}^{\infty} p_{ik} s^i t^k, \quad s, t \in [-1, 1]$$

为 (X, Y) 的概率母函数。[Lec12_2026_0520.pdf P22]

原理与推导 二维 PGF 是一维情形的直接推广, 其核心价值在于刻画两变量间的关系。

• 性质:

1. 有界性: $|g(s, t)| \leq g(1, 1) = 1$, 当 $|s| \leq 1, |t| \leq 1$ 。
2. 边际性: $g_X(s) = g(s, 1)$, $g_Y(t) = g(1, t)$ 。
3. 独立性判据: X 与 Y 相互独立, 当且仅当 $g(s, t) = g_X(s) \cdot g_Y(t)$ 对所有 s, t 成立。
4. 联合分布列提取: $p_{ik} = \frac{1}{i!k!} \cdot \frac{\partial^{i+k} g(s, t)}{\partial s^i \partial t^k} \Big|_{s=0, t=0}$ 。[Lec12_2026_0520.pdf P23]

解题步骤

- **判独立:** 计算 $g(s, t)$, 再分别计算 $g(s, 1)$ 和 $g(1, t)$ 。验证 $g(s, t) = g(s, 1) \cdot g(1, t)$ 是否成立。
- **求边际分布列:** 对联合 PGF 分别令 $t = 1$ 或 $s = 1$, 得到边际 PGF, 再按一维方法提取概率。

易错点

- **独立性的充分必要性:** PGF 的可乘性 $g(s, t) = g_X(s)g_Y(t)$ 是独立的充要条件, 比相关系数为零等条件强得多, 是判断独立的强有力工具。
- **与协方差/相关系数的区别:** 两个随机变量的 PGF 满足乘积分解等价于独立, 但协方差为 0 只是不相关的必要条件, 不能推出独立。PGF 是判定非负整值变量独立性的终极标准之一。

(自编, 基于课件性质 [Lec12_2026_0520.pdf P23])

题目

设非负整数值随机向量 (X, Y) 的联合 PGF 为 $g(s, t) = \frac{1}{4}(1 + s + t + st)$ 。(1) 判断 X 与 Y 是否独立; (2) 求 X 的边际分布列。

思路

展开联合 PGF 得联合分布列; 利用 $g(s, 1)$ 求边际 PGF, 再展开得边际分布列; 比较 $g(s, t)$ 和 $g_X(s)g_Y(t)$ 判断独立性。

解答

1. 展开联合 PGF: $g(s, t) = \frac{1}{4}s^0t^0 + \frac{1}{4}s^1t^0 + \frac{1}{4}s^0t^1 + \frac{1}{4}s^1t^1$, 故联合分布列 $p_{00} = p_{10} = p_{01} = p_{11} = \frac{1}{4}$ 。2. 求边际 PGF: $g_X(s) = g(s, 1) = \frac{1}{4}(1 + s + 1 + s) = \frac{1}{2}(1 + s) = \frac{1}{2}s^0 + \frac{1}{2}s^1$, 对应 $\mathbb{P}(X = 0) = \frac{1}{2}, \mathbb{P}(X = 1) = \frac{1}{2}$, 所以 $X \sim B(1, 0.5)$ 。3. 同理 $g_Y(t) = g(1, t) = \frac{1}{2}(1 + t)$, $Y \sim B(1, 0.5)$ 。4. 独立性判断: 计算 $g_X(s)g_Y(t) = \frac{1}{2}(1+s) \cdot \frac{1}{2}(1+t) = \frac{1}{4}(1+s+t+st) = g(s, t)$ 恒成立, 故 X 与 Y 相互独立。

技巧

二维 PGF 的因子分解能力是判别独立的利器。只要联合 PGF 能写成一元函数的乘积, 且各因子恰为边际 PGF, 则独立。

五) 从 PGF 到 MGF 的过渡 **重点**

原理与推导 概率母函数 $g(s) = \mathbb{E}[s^X]$ 只适用于非负整值变量。若随机变量可取负数或非整数 (如正态分布), $\mathbb{E}[s^X]$ 可能无法良好定义。为了解决这个问题, 我们将基底 s 替换为 e^t , 得到:

$$\mathbb{E}[e^{tX}]$$

当 t 使期望存在时, 该函数称为**矩母函数** (MGF)。MGF 适用于任何实值随机变量, 并且其各阶导数在 $t = 0$ 处的值直接给出各阶原点矩: $\mathbb{E}[X^k] = M^{(k)}(0)$ 。[Lec12_2026_0520.pdf P24]

易错点

- PGF 与 MGF 的联系: 形式上, MGF $M(t) = \mathbb{E}[e^{tX}]$, PGF 为 $\mathbb{E}[s^X]$ 。因此, 当 X 取值非负整数时, 有 $M(t) = g(e^t)$ 或 $g(s) = M(\ln s)$ 。
- PGF 的局限性是引入 MGF 的直接动机。

本章小结

- 知识关系:** 本章介绍了研究非负整数值随机变量的核心工具——概率母函数 (PGF)。PGF 的解析性质 (可逐项求导) 搭建了从“生成函数”到“概率/数字特征”的桥梁。独立性假设下, PGF 的乘法性质极大简化了随机变量和的分布研究。PGF 的局限性自然地引出了适用范围更广的矩母函数 (MGF)。
- 核心结论:**
 - PGF 可唯一确定非负整数值随机变量的分布列。
 - 利用 PGF 的导数可轻松计算期望和方差: $\mathbb{E}[X] = g'(1)$, $\text{Var}(X) = g''(1) + g'(1) - [g'(1)]^2$ 。
 - 独立随机变量和的 PGF 等于它们各自 PGF 的乘积。
- 必背公式:**

- **PGF 定义**: $g(s) = \sum_{j=0}^{\infty} s^j \mathbb{P}(X = j)$
- **求期望**: $\mathbb{E}[X] = g'(1)$
- **求方差**: $\text{Var}(X) = g''(1) + g'(1) - [g'(1)]^2$
- **二项分布 PGF**: $B(n, p) : g(s) = (q + sp)^n$
- **泊松分布 PGF**: $\mathcal{P}(\lambda) : g(s) = e^{\lambda(s-1)}$
- **几何分布 PGF**: $G(p) : g(s) = \frac{sp}{1 - sq}$

- **记忆** 一句话记忆: PGF 是概率的幂级数“生成器”, 在 1 处求导得期望, 独立场合乘积化。

矩母函数 高频

定义 设 X 是一个随机变量, 若对于某个 $h > 0$, 期望 $E[e^{sX}]$ 对所有 $|s| < h$ 均存在, 则称函数

$$M_X(s) = E[e^{sX}]$$

为 X 的矩母函数 (Moment Generating Function, MGF) [Lec12_2026_0520.pdf P26]

- 离散变量: $M_X(s) = \sum_k e^{sx_k} \mathbb{P}(X = x_k)$
- 连续变量: $M_X(s) = \int_{-\infty}^{+\infty} e^{sx} f_X(x) dx$

原理与推导矩母函数因其能“生成”各阶矩而得名。将指数函数 e^{sX} 在 $s = 0$ 处进行 Taylor 展开, 并对两边取期望得到:

$$M_X(s) = E \left[\sum_{k=0}^{\infty} \frac{(sX)^k}{k!} \right] = \sum_{k=0}^{\infty} \frac{E[X^k]}{k!} s^k$$

这意味着 k 阶矩 $E[X^k]$ 正是 $M_X(s)$ 在 0 点 Taylor 展开中 $\frac{s^k}{k!}$ 项的系数。因此, 对矩母函数求 k 次导数并在 $s = 0$ 处求值, 便得到 k 阶矩:

$$E[X^k] = M_X^{(k)}(0), \quad k = 1, 2, \dots$$

[Lec12_2026_0520.pdf P27]

矩母函数的性质 **必背** 设随机变量 X 的矩母函数为 $M_X(s)$ 。

1. **生成矩**: $E[X^k] = M_X^{(k)}(0)$
2. **唯一性**: 若 $M_X(s)$ 在 $s = 0$ 附近存在, 则它唯一地决定了 X 的分布函数。(不要求证明)
3. **线性变换**: 若 $Y = aX + b$, 则 Y 的矩母函数为:

$$M_Y(s) = e^{sb} M_X(as)$$

4. **独立和**: 若 $X_1, X_2, \dots, X_n$ 相互独立, 其矩母函数分别为 $M_{X_i}(s)$, 则它们的和 $S_n = X_1 + \dots + X_n$ 的矩母函数为:

$$M_{S_n}(s) = \prod_{i=1}^n M_{X_i}(s)$$

[Lec12_2026_0520.pdf P27]

常见分布的矩母函数 **必背**

分布	PGF	MGF	备注
			[Lec12_2026_0520.pdf P30, P32, P34]
二项分布 $B(n, p)$	$(q + ps)^n$	$(q + pe^s)^n$	$q = 1 - p$
泊松分布 $\mathcal{P}(\lambda)$	$e^{\lambda(s-1)}$	$e^{\lambda(e^s-1)}$	
指数分布 $Exp(\lambda)$	-	$\frac{\lambda}{\lambda-s}$	存在域为 $s < \lambda$
标准正态分布 $N(0, 1)$	-	$e^{\frac{s^2}{2}}$	
一般正态分布 $N(\mu, \sigma^2)$	-	$e^{\mu s + \frac{\sigma^2 s^2}{2}}$	
均匀分布 $U(a, b)$	-	$\frac{e^{sb} - e^{sa}}{s(b-a)}$	特殊情况 $s = 0$ 时取极限值为 1

解题步骤

1. **求矩**: 给定分布, 可先求 MGF, 再求导并令 $s = 0$ 得各阶矩。导数的计算往往比直接积分/求和简便。
2. **求独立和的分布**: 当难以直接计算独立随机变量和的分布时, 可利用性质 4。将各独立成分的 MGF 相乘, 观察所得 MGF 形式, 由唯一性识别和的分布。
3. **判断分布类型**: 熟记常见分布的 MGF 形式。当遇到一个形式复杂但实际是常见分布 MGF 乘积的函数时, 可直接用唯一性判断分布, 无需从 pdf/pmf 重新推导。

易错点

- **MGF 可能不存在**: 并非所有分布都有矩母函数。例如, 柯西分布 (Cauchy Distribution) 的矩母函数不存在, 因为积分 $\int e^{sx} \frac{1}{\pi(1+x^2)} dx$ 对任何 $s \neq 0$ 都发散至无穷。[Lec12_2026_0520.pdf P37]
- **定义域的重要性**: MGF 是在 $s = 0$ 附近的邻域定义的。如指数分布的 MGF 只对 $s < \lambda$ 有定义。讨论 MGF 时必须注意其定义域。
- **不要混淆独立和与非独立和**: 性质 4 (MGF 的乘积) 仅对独立随机变量之和成立。
- **PGF 与 MGF 的混淆**:

特征	概率母函数 (PGF)	矩母函数 (MGF)
定义	$g(s) = E[s^X]$	$M(s) = E[e^{sX}]$
主要应用	非负整数值随机变量	更广泛的连续/离散随机变量
与矩的关系	$E[X] = g'(1)$	$E[X^k] = M^{(k)}(0)$
关系	$M_X(s) = g_X(e^s)$	$g_X(s) = M_X(\ln s)$

例 2.1 (均匀分布的矩母函数) [Lec12_2026_0520.pdf P31]

例题

题目

设 $X \sim U(a, b)$, 求其矩母函数 $M_X(s)$ 。

思路

直接应用连续随机变量矩母函数的定义进行计算。

解答

1. 代入定义: $M_X(s) = \int_a^b e^{sx} \cdot \frac{1}{b-a} dx$ 2. 积分求解: $M_X(s) = \frac{1}{s(b-a)} [e^{sx}]_a^b$ 3. 代入上下限: $M_X(s) = \frac{e^{sb} - e^{sa}}{s(b-a)}$ (当 $s \neq 0$ 时; $M(0) = 1$ 为其极限)

技巧

此处的积分非常基础, 关键点在于最后结果形式, 可用于结合性质 2 (唯一性) 判断某复杂形式是否来自均匀分布。

例 2.2 (指数分布的矩母函数与矩) [Lec12_2026_0520.pdf P32]

例题

题目

设 $X \sim \text{Exp}(\lambda)$, 密度函数为 $f(x) = \lambda e^{-\lambda x} I_{(x>0)}$ 。求 (1) 矩母函数 $M_X(s)$; (2) 期望 $E[X]$ 和二阶矩 $E[X^2]$ 。

思路

先利用连续随机变量定义计算 MGF, 再通过对 MGF 求导得到各阶矩。

解答

1. 求 MGF: 对 $s < \lambda$, 有

$$M_X(s) = \int_0^{\infty} e^{sx} \cdot \lambda e^{-\lambda x} dx = \lambda \int_0^{\infty} e^{(s-\lambda)x} dx = \lambda \left[\frac{e^{(s-\lambda)x}}{s-\lambda} \right]_0^{\infty} = \frac{\lambda}{\lambda-s}$$

2. 求一阶矩 $E[X]$: 对 MGF 求一阶导: $M'(s) = \frac{\lambda}{(\lambda-s)^2}$ 。令 $s = 0$, 得 $E[X] = M'(0) = \frac{1}{\lambda}$ 。3. 求二阶矩 $E[X^2]$: 对 MGF 求二阶导: $M''(s) = \frac{2\lambda}{(\lambda-s)^3}$ 。令 $s = 0$, 得 $E[X^2] = M''(0) = \frac{2}{\lambda^2}$ 。

技巧

求矩母函数后再求导, 比直接积分 $\int x^n \lambda e^{-\lambda x} dx$ 每次都要分部积分要更快且不易出错。

例 2.3 (独立正态分布之和的分布) [Lec12_2026_0520.pdf P34]

例题

题目

设 $X \sim N(\mu_1, \sigma_1^2)$ 与 $Y \sim N(\mu_2, \sigma_2^2)$ 相互独立。使用矩母函数证明 $Z = X + Y$ 服从 $N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$ 。

思路

利用“线性变换性质”先求出 X, Y 的 MGF，再利用“独立和性质”将它们相乘，最后观察乘积结果的形式，由“唯一性”得出结论。

解答

1. **建立基础**: 已知标准正态分布 $V \sim N(0, 1)$ 的 MGF 为 $M_V(s) = e^{s^2/2}$ 。2. **求一般正态分布的 MGF**: 由 $W = \mu + \sigma V \sim N(\mu, \sigma^2)$, 利用性质 3 得 $M_W(s) = e^{\mu s} M_V(\sigma s) = e^{\mu s + \frac{\sigma^2 s^2}{2}}$ 。3. **求 Z 的 MGF**:
$$M_Z(s) = M_X(s) \cdot M_Y(s) = \exp\left(\mu_1 s + \frac{\sigma_1^2 s^2}{2}\right) \cdot \exp\left(\mu_2 s + \frac{\sigma_2^2 s^2}{2}\right) = \exp\left((\mu_1 + \mu_2)s + \frac{(\sigma_1^2 + \sigma_2^2)s^2}{2}\right)$$
4. $M_Z(s) = \exp\left((\mu_1 + \mu_2)s + \frac{(\sigma_1^2 + \sigma_2^2)s^2}{2}\right) = M_{N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)}(s)$ 。证毕。

技巧

矩母函数的最大价值体现在这类问题上：**求独立随机变量和的分布**。它将复杂的卷积运算转化为简单的函数相乘，结合唯一性，威力巨大。

特征函数 **重点**

对于任意随机变量 X ，其特征函数 (Characteristic Function, C.F.) 定义为

$$\phi_X(t) = E[e^{itX}] = E[\cos(tX) + i \sin(tX)], \quad t \in \mathbb{R}$$

其中 $i = \sqrt{-1}$ 为虚数单位。[Lec12_2026_0520.pdf P39]

特征函数与矩母函数的定义区别在于用 it 替代了 s 。由于欧拉公式 $e^{i\varphi} = \cos \varphi + i \sin \varphi$ ，使得 $|e^{itX}| \equiv 1$ ，积分/求和总是绝对收敛。这克服了矩母函数可能不存在的缺陷（如柯西分布），使得每个随机变量的特征函数都存在，成为一种应用更广泛的分布刻画工具。[Lec12_2026_0520.pdf P37, P39]

与矩母函数的关系形式上， $\phi_X(t) = M_X(it)$ 。很大程度上，矩母函数的性质（线性变换、独立和的乘法等）可以平移到特征函数上。求矩时，则有 $E[X^k] = \frac{1}{i^k} \phi^{(k)}(0)$ 。

随机向量的矩母函数对于随机向量 $\vec{X} = (X_1, \dots, X_n)^T$ ，定义多元矩母函数：

$$M_{\vec{X}}(\vec{s}) = E[e^{\vec{s}^T \vec{X}}] = E[e^{s_1 X_1 + \dots + s_n X_n}], \quad \vec{s} \in \mathbb{R}^n$$

[Lec12_2026_0520.pdf P36]

(自编, 基于课件中 MGF 与 CF 关系及正态分布性质)

题目

设 $X \sim N(0, 1)$, 利用矩母函数求其特征函数 $\phi_X(t)$; 并求 $Y = X_1 + X_2$ 的特征函数, 其中 X_1, X_2 i.i.d. $N(0, 1)$ 。

思路

利用 $\phi_X(t) = M_X(it)$ 转换, 再通过独立和性质得到 Y 的特征函数。

解答

1. 求 $\phi_X(t)$: 已知 $X \sim N(0, 1)$ 的 MGF 为 $M_X(s) = e^{s^2/2}$, 故 $\phi_X(t) = M_X(it) = e^{(it)^2/2} = e^{-t^2/2}$ 。2. 求 Y 的 CF: 由于 X_1, X_2 独立, 特征函数具有乘积性质: $\phi_Y(t) = \phi_{X_1}(t) \cdot \phi_{X_2}(t) = e^{-t^2/2} \cdot e^{-t^2/2} = e^{-t^2}$ 。3. 识别分布: e^{-t^2} 符合 $N(0, 2)$ 的特征函数形式 (因为 $N(\mu, \sigma^2)$ 的 CF 为 $e^{i\mu t - \sigma^2 t^2/2}$, 此处 $\mu = 0, \sigma^2 = 2$), 故 $Y \sim N(0, 2)$ 。

技巧

特征函数的计算常借助已知的 MGF, 代换 $s = it$ 即可; 独立和的特征函数等于特征函数的乘积, 这与 MGF 一致。

本章小结

本章系统介绍了刻画随机变量分布的两类解析工具: 概率母函数 (PGF)、矩母函数 (MGF), 并简要引入特征函数 (C.F.)。其核心路径是从“分布列/密度函数”过渡到“函数”, 利用函数的代数运算简化概率问题。

本章知识关系: 本章从 PGF 扩展到 MGF, 再推广至适用范围更广的 C.F.。PGF 擅长处理非负整数离散随机变量及其和; MGF 作为核心工具, 将求矩、求独立和分布等问题函数化; C.F. 作为 MGF 的复数域推广, 提供了理论上的完美解决方案。

核心结论:

- **PGF:** $g_X(s) = E[s^X]$, X 为非负整数。主要性质: $P(X = k) = g^{(k)}(0)/k!$, $E[X] = g'(1)$ 。
- **MGF:** $M_X(s) = E[e^{sX}]$, 性质更强。核心在于 $E[X^k] = M^{(k)}(0)$ 和独立随机变量和的 MGF 等于各自 MGF 之积。
- **C.F.:** $\phi_X(t) = E[e^{itX}]$, 始终存在, 是理论分析利器。

必背公式:

- 关系: $M_X(s) = g_X(e^s)$
- MGF 求矩: $E[X^k] = M_X^{(k)}(0)$
- 线性变换: $M_{aX+b}(s) = e^{sb} M_X(as)$

- 独立和: $M_{X_1+\dots+X_n}(s) = \prod_{i=1}^n M_{X_i}(s)$
- 二项分布 $B(n, p)$ 的 MGF: $(q + pe^s)^n$
- 泊松分布 $\mathcal{P}(\lambda)$ 的 MGF: $e^{\lambda(e^s-1)}$
- 指数分布 $Exp(\lambda)$ 的 MGF: $\frac{\lambda}{\lambda-s}$ ($s < \lambda$)
- 正态分布 $N(\mu, \sigma^2)$ 的 MGF: $e^{\mu s + \frac{\sigma^2 s^2}{2}}$

记忆 MGF 像幂级数版 PGF, 指数项换底 $s \rightarrow e^s$, 核心是求矩导 0 和独立和相乘。

第 3 章特征函数与大数定律

特征函数 重点

定义 设 X 为随机变量, 称

$$\phi_X(t) = \mathbb{E}[e^{itX}] = \mathbb{E}[\cos(tX) + i \sin(tX)], \quad t \in \mathbb{R}$$

为 X 的特征函数, 其中 $i = \sqrt{-1}$ 。

原理与推导

1. 与矩母函数的关系:

- 矩母函数: $M_X(s) = \mathbb{E}[e^{sX}]$, 当期望存在时成立。
- 特征函数: 将矩母函数中的 s 替换为 it , 即 $\phi_X(t) = M_X(it)$ 。
- 核心区别: 矩母函数 $\mathbb{E}[e^{sX}]$ 可能因 s 导致积分发散 (如柯西分布); 而 $|e^{itX}| \equiv 1$, 使得特征函数 $\phi_X(t)$ 对任意随机变量 X 始终存在且 $|\phi_X(t)| \leq 1$ 。

2. 直观理解:

- 正交坐标系: 类似于向量在正交基下的坐标表示, $\{e^{itx} = \cos(tx) + i \sin(tx)\}$ 构成一组连续的正交基。
- 时域到频域: 概率密度函数 $f(x)$ (时域) 与特征函数 $\phi(t)$ (频域) 构成傅里叶变换对:

$$\phi(t) = \int_{-\infty}^{\infty} f(x) e^{itx} dx \quad (\text{傅里叶变换})$$

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \phi(t) e^{-itx} dt \quad (\text{傅里叶逆变换})$$

特征函数的基本性质 必背 设 $\phi_X(t) = \mathbb{E}[e^{itX}]$, 则:

1. 有界性: $|\phi_X(t)| \leq 1$ 。
2. 初值与导数: $\phi_X(0) = 1$ 。若 $\mathbb{E}[|X|^k] < \infty$, 则 $\phi_X^{(k)}(t) = i^k \mathbb{E}[X^k e^{itX}]$, 进而可得原点矩: $\phi_X^{(k)}(0) = i^k \mathbb{E}[X^k]$ 。
3. 独立和的变换: 若 $X_1, \dots, X_n$ 相互独立, $Y = X_1 + \dots + X_n$, 则 $\phi_Y(t) = \prod_{j=1}^n \phi_{X_j}(t)$ 。

4. 线性变换: 对常数 a, b , 有 $\phi_{aX+b}(t) = e^{itb}\phi_X(at)$ 。

常见分布的特征函数 必背

分布类型	概率母函数 (PGF) $g(s)$	矩母函数 (MGF) $M(s)$	特征函数 $\phi(t)$
二项分布 $B(n, p)$	$(q + ps)^n$	$(q + pe^s)^n$	$(q + pe^{it})^n$
泊松分布 $\mathcal{P}(\lambda)$	$e^{\lambda(s-1)}$	$e^{\lambda(e^s-1)}$	$e^{\lambda(e^{it}-1)}$
几何分布 $G(p)$	$\frac{sp}{1-sq}$	$\frac{e^s p}{1-e^s q}$	$\frac{e^{it} p}{1-e^{it} q}$
均匀分布 $U(a, b)$	—	$\frac{e^{sb}-e^{sa}}{(b-a)s}$	$\frac{e^{itb}-e^{ita}}{it(b-a)}$
指数分布 $\text{Exp}(\lambda)$	—	$(1 - \frac{s}{\lambda})^{-1}$	$(1 - \frac{it}{\lambda})^{-1}$
正态分布 $N(\mu, \sigma^2)$	—	$e^{\mu s + \frac{\sigma^2 s^2}{2}}$	$e^{i\mu t - \frac{\sigma^2 t^2}{2}}$
柯西分布	—	不存在	$e^{- t }$

解题步骤

1. 求特征函数:

- 直接使用定义 $\phi_X(t) = \mathbb{E}[e^{itX}]$, 分别按离散型 (求和) 和连续型 (积分) 计算。
- 灵活运用性质 4 (线性变换) 和性质 3 (独立和) 简化计算。

2. 求原点矩:

- 对特征函数求 k 阶导数: $\mathbb{E}[X^k] = i^{-k}\phi_X^{(k)}(0)$ 。

3. 判定独立性:

- 计算随机向量的联合特征函数 $\phi_{\mathbf{X}}(\mathbf{t})$ 。
- 若它能分解为各分量特征函数之积 $\prod \phi_{X_j}(t_j)$, 则各分量相互独立。

易错点

- 特征函数与矩母函数公式混淆: 计算特征函数时, 容易忘记将 s 替换为 it 。例如指数分布的矩母函数为 $\frac{1}{1-s/\lambda}$, 其特征函数是 $\frac{1}{1-it/\lambda}$, 而非 $\frac{1}{1-t/\lambda}$ 。
- 正态分布特征函数: 需牢记指数项 $i\mu t - \frac{\sigma^2 t^2}{2}$, 其中方差项系数为负, t 为二次方。
- 独立和的特征函数: 只有当 X_i 相互独立时, 和的特征函数才等于各特征函数之积。独立是充要条件。

例题

[Lec13_2026_0527.pdf P22]

题目

设 X, Y 为随机变量, 且 $\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t), \forall t \in \mathbb{R}$ 。问 X 与 Y 是否一定独立?

思路

本题考察特征函数判定独立性的适用条件。独立性能推出联合特征函数可分解, 但其逆命题是否成立? 需要注意定理要求的是随机向量的联合特征函数, 而非和的分解形式。

解答

不一定。特征函数判定独立性的定理指出: $X_1, \dots, X_n$ 相互独立的充要条件是联合特征函数等于各边缘特征函数之积, 即 $\phi_{\mathbf{X}}(\mathbf{t}) = \prod \phi_{X_j}(t_j)$ 。题目中的条件 $\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t)$ 仅仅是和的特征函数分解, 并不等价于联合特征函数可分解。仅由 $\phi_{X+Y}(t) = \phi_X(t)\phi_Y(t)$ 并不能推出 X 与 Y 独立。

技巧

区分“和的分布特征”与“联合分布特征”。独立性判定必须基于联合特征函数的分解, 不能仅看和的分解。

本章总览

本章为“特征函数与大数定律”的后半部分, 核心是建立收敛概念并理解大数定律的多种形式。高频考点集中在依概率收敛的定义与判别、基础版弱大数定律 (WLLN) 的证明与应用 (尤其是计算样本量)、以及几乎必然收敛与依概率收敛的对比。方法上, 必须掌握通过切比雪夫/马尔可夫不等式建立概率上界以证明收敛的典型套路, 并能区分弱大数定律 (依概率收敛) 与强大数定律 (几乎必然收敛 / 以概率 1 收敛) 的条件与结论差异。

依概率收敛 必背

设 $\{X_n\}$ 是随机变量序列, X 为一随机变量。若对 $\forall \varepsilon > 0$, 有:

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

则称 $\{X_n\}$ 依概率收敛于 X , 记作 $X_n \xrightarrow{P} X$ 。

1. **核心思想**: 将随机变量的收敛问题转化为一个普通数列的极限问题。我们关注的不是 X_n 在每一点的取值, 而是“ X_n 与 X 出现大偏差”这一事件的概率是否趋于 0。
2. **大数定律的特例**: 当极限 X 是一个常数 c (即退化随机变量) 时, 就是大数定律所描述的情形, 比如样本均值 $\bar{X}_n$ 依概率收敛到总体期望 μ 。
3. **为什么需要 $\forall \varepsilon > 0$** : 这保证了对任意小的允许偏差, 出现大偏差的概率最终都会任意小, 是严格的收敛定义, 而非仅排除偏差为 0 的情形。

4. **明确对象**: 指出需要证明收敛的随机变量 X_n 和目标 X 。
 5. **转化目标**: 对任意给定的 $\varepsilon > 0$, 写出需要证明的概率 $P(|X_n - X| > \varepsilon)$ 。
 6. **构造不等式**: 通常利用切比雪夫 (Chebyshev) 不等式或马尔可夫 (Markov) 不等式对概率进行放大。
 7. **求极限**: 证明放大后的上界关于 n 取极限为 0, 根据夹逼准则, 原概率的极限即为 0。
 8. **得出结论**: 依据定义, 判定 $X_n \xrightarrow{P} X$ 。
- **混淆收敛对象**: 依概率收敛的极限通常是一个常数 (如 $E[X]$), 而不是一个分布。虽然极限可以是随机变量, 但在大数定律中通常是常数。
 - **ε 的任意性**: 定义中 $\forall \varepsilon > 0$ 不可遗漏, 它保证了收敛的严格性。只证明 $P(|X_n - X| > 0) \rightarrow 0$ 是错误且不充分的。
 - **“概率”与“确定”**: 依概率收敛是“概率”的收敛, 并非“必然”的逐点收敛。它允许在某个 n 时出现较大偏差, 只要这种可能性趋于 0 即可。

对比项	依概率收敛
关注点	出现偏差的 概率 的极限
符号	$X_n \xrightarrow{P} X$
定义核心	$\forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(X_n - X > \varepsilon) = 0$
概率意义	大偏差 发生的概率趋向于 0
与必然收敛的关系	“必然收敛”一定可推出“依概率收敛”, 反之则不一定。

弱大数定律 (WLLN) 及其证明 **必背**

定理 2.1 (弱大数定律, WLLN): 设 $\{X_i\}$ 是独立同分布的随机变量序列, 且 $\text{Var}(X_i) < \infty$, $\mu = E[X_i]$ 。则对任意 $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} P\left(\left|\frac{1}{n} \sum_{i=1}^n X_i - \mu\right| \geq \varepsilon\right) = 0$$

即样本均值 $\frac{1}{n} \sum_{i=1}^n X_i$ 依概率收敛到总体均值 μ 。

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

推导 (证明): 目标是建立 $\frac{1}{n} \sum_{i=1}^n X_i$ 的方差与 n 的关系, 并使用切比雪夫不等式。

记 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$, 则:

$$E[\bar{X}_n] = \frac{1}{n} \sum_{i=1}^n E[X_i] = \mu$$

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right)$$

由独立性（和方差关系）：

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i)$$

由同分布，记 $\sigma^2 = \text{Var}(X_i)$ ，则：

$$\text{Var}(\bar{X}_n) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$$

接着，应用切比雪夫不等式（见下面不等式章节）：对任意 $\varepsilon > 0$ ，

$$0 \leq P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}$$

当 $n \rightarrow \infty$ 时，上界 $\frac{\sigma^2}{n\varepsilon^2} \rightarrow 0$ ，由夹逼定理得证。

1. 验证条件：检查序列 $\{X_n\}$ 是否满足独立同分布（基础版 WLLN）且方差有限。
 2. 定义样本均值：写出 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ 。
 3. 计算均值和方差：求出 $E[\bar{X}_n]$ （通常为 X 的期望）和 $\text{Var}(\bar{X}_n)$ 。
 4. 应用不等式：使用切比雪夫不等式缩放概率。
 5. 求极限并结论：证明缩放后的上界趋于 0，因此 $\bar{X}_n$ 依概率收敛到 $E[X]$ 。
- 方差有限条件：基础版 WLLN 要求方差有限，这是一个关键前提。
 - ε 的下标：概率不等式中，左边往往是 $\geq \varepsilon$ 或 $> \varepsilon$ ，两者在使用切比雪夫不等式时是等价的。
 - 证明逻辑：不能用样本均值的表达式直接代入 $|\dots|$ 里面去化解，必须借助概率不等式。

不等式：切比雪夫不等式与马尔可夫不等式 高频

马尔可夫 (Markov) 不等式：对非负随机变量 X 和任意 $\varepsilon > 0$ ，

$$P(X \geq \varepsilon) \leq \frac{E[X]}{\varepsilon}$$

更一般地，对 $\alpha > 0$ ，

$$P(|X| \geq \varepsilon) \leq \frac{E[|X|^\alpha]}{\varepsilon^\alpha}$$

切比雪夫 (Chebyshev) 不等式（推论）：对随机变量 X ，其期望 $E[X] = \mu$ ，方差 $\text{Var}(X) = \sigma^2 < \infty$ ，则：

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

切比雪夫不等式可视为马尔可夫不等式的特例，取新变量 $Y = (X - \mu)^2$ ，则 $E[Y] = \sigma^2$ ，应用马尔可夫不等式，

$$P(|X - \mu| \geq \varepsilon) = P((X - \mu)^2 \geq \varepsilon^2) \leq \frac{E[(X - \mu)^2]}{\varepsilon^2} = \frac{\sigma^2}{\varepsilon^2}$$

1. 识别应用场景：通常需要放缩概率 $P(|X - E[X]| \geq \varepsilon)$ 或类似形式。
2. 选择不等式：
 - 如果概率涉及“偏离期望一定距离”，优先尝试切比雪夫不等式。
 - 如果 X 是非负的，可尝试马尔可夫不等式。
3. 代入计算：匹配不等式各部分，代入均值和方差。
4. 目标：得到一个只含常数和 n (或 ε) 的上界，从而可以求极限或解不等式。

对比项	马尔可夫不等式	切比雪夫不等式
适用对象	非负随机变量 $X \geq 0$	任何方差有限的随机变量
所需量	期望 $E[X]$	期望 $E[X]$ 和方差 $\text{Var}(X)$
不等式形式	$P(X \geq a) \leq E[X]/a$	$P(X - E[X] \geq b) \leq \text{Var}(X)/b^2$
在 WLLN 中的应用	不直接使用	直接使用，构造出 $\frac{\sigma^2}{n\varepsilon^2}$ 的上界

应用：根据精度确定样本量 [Lec13_2026_0527.pdf P33-34]

题目

设人群中疫苗有效的比例为 p 。随机抽取 n 个人，用 X_i 表示疫苗对第 i 个人是否有效 (X_i 是伯努利变量)。现在用样本中疫苗有效的比例 $M_n = \frac{1}{n} \sum_{i=1}^n X_i$ 去估计 p 。问至少需要调查多少人 (n)，才能保证样本比例与真实比例 p 的误差大于 3% 的概率不超过 5%? (即 $P(|M_n - p| \geq 0.03) \leq 0.05$)

思路

这是一个典型的“给定精度和置信度，求样本量”的 WLLN 应用问题。核心是利用 WLLN 证明中使用的切比雪夫不等式建立 $P(|M_n - p| \geq 0.03)$ 的上界函数，再令该上界 ≤ 0.05 解出 n 。上界函数包含了 $\text{Var}(X_i)$ ，可求得伯努利变量方差的最大值为 $1/4$ 。

解答

1. X_i 是独立同分布的伯努利变量, $E[X_i] = p$, $\text{Var}(X_i) = p(1-p)$ 。2. 样本均值 M_n 的期望为 $E[M_n] = p$, 方差为 $\text{Var}(M_n) = \frac{p(1-p)}{n}$ 。3. 应用切比雪夫不等式:

$$P(|M_n - p| \geq 0.03) \leq \frac{\text{Var}(M_n)}{0.03^2} = \frac{p(1-p)}{n \cdot 0.03^2}$$

4. 对于 $0 \leq p \leq 1$, 方差 $p(1-p)$ 的最大值为 $1/4$ 。因此, 不等式可放大为:

$$P(|M_n - p| \geq 0.03) \leq \frac{1/4}{n \cdot 0.0009} = \frac{1}{n \cdot 0.0036}$$

5. 要使概率不超过 0.05, 只需:

$$\frac{1}{n \cdot 0.0036} \leq 0.05$$

$$n \geq \frac{1}{0.05 \cdot 0.0036} = \frac{1}{0.00018} \approx 5555.56$$

因此, 取 $n = 5556$ 即可满足要求。

技巧

当总体方差未知时, 常利用伯努利分布方差上界 $1/4$ 来计算最保守 (所需样本量最大) 的情况, 这能保证对任意的 p 都满足精度要求。

大数定律条件的放宽 **重点**

1. 马尔可夫大数定律: 放宽了“独立同分布”条件。设 $\{X_i\}$ 是同分布的随机变量序列, 且 $\text{Var}(\frac{1}{n} \sum_{i=1}^n X_i) \rightarrow 0$, 则

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} E[X_1]$$

2. 辛钦大数定律: 放宽了“方差有限”条件。设 $\{X_i\}$ 是独立同分布 (i.i.d.) 的随机变量序列, 且 $E[X_i] = \mu < \infty$, 则

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

(此定律去掉了对 $\text{Var}(X_i) < \infty$ 的要求, 是基础版 WLLN 的推广)

• 版本混淆:

- 基础版 WLLN: i.i.d. + 方差有限
- 辛钦大数定律: i.i.d. + 期望有限 (方差可无限)
- 马尔可夫大数定律: 同分布 + 样本均值方差趋于 0 (可去独立性)

- 条件与结论: 虽然辛钦定律条件更弱, 但其证明需要用到特征函数 (或更高阶工具), 在考研/常规题目中, 基础版 WLLN 的证明和计算是绝对重点。

几乎必然收敛 (以概率 1 收敛) 与强大数定律 **重点**

设 $\{X_n\}$ 是随机变量序列, X 为一随机变量。若

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

则称 $\{X_n\}$ 几乎必然收敛 (或称以概率 1 收敛) 于 X , 记作 $X_n \xrightarrow{a.s.} X$ 。

1. 与“依概率收敛”的直观对比:

- 依概率收敛 $X_n \xrightarrow{P} X: \forall \varepsilon > 0, \lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$ 。关注的是“在每一个时刻 n , 出现大偏差的概率公式趋于 0”。这是概率的数列极限。
- 几乎必然收敛 $X_n \xrightarrow{a.s.} X: P(\lim_{n \rightarrow \infty} X_n = X) = 1$ 。关注的是“对于每个样本点 ω , 序列 $\{X_n(\omega)\}$ 是否逐点收敛到 $X(\omega)$ ”。这是随机变量作为函数的逐点收敛, 且该事件发生的概率为 1。

2. 强弱关系: 几乎必然收敛 $\implies$ 依概率收敛, 反之则不然。课件 [Lec14_2026_0603.pdf P9-P11] 中的例子说明了一个序列可以依概率收敛到 0, 但以概率 1 不存在极限。

强大数定律 (SLLN) 定理 1.2 (强大数定律, SLLN): 设 $\{X_i\}$ 是独立同分布的随机变量序列, 若 $E[X_i] = \mu < \infty$, 则样本均值几乎必然收敛于 μ :

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{a.s.} \mu$$

重要注解:

- 频率的收敛: 强大数定律保证了事件 A 发生的频率 $\frac{1}{n} \sum_{i=1}^n I_{\{X_i \in A\}}$ 几乎必然收敛于其概率 $P(A)$ 。这意味着, 对“几乎所有”的实现路径, 频率最终都会稳定在概率附近。
- 蒙特卡洛模拟的基石: 因为是“几乎必然收敛”, 所以任何一次足够长的随机模拟, 其得到的结果都会逼近真实值, 这是蒙特卡洛方法的理论基础。

对比项	依概率收敛	几乎必然收敛
关注的收敛	概率的极限	随机变量作为函数, 逐点收敛的概率
定义公式	$\lim_{n \rightarrow \infty} P(X_n - X > \varepsilon) = 0$	$P(\lim_{n \rightarrow \infty} X_n = X) = 1$
WLLN vs SLLN	WLLN (方差有限) 或辛钦过程 (期望有限)	SLLN (期望有限)
相对强弱	较弱	较强 ($a.s.$ 收敛可推出 P 收敛)
概率意义	当 n 很大时, 大偏差出现的概率很小	当 n 很大时, 几乎所有路径都接近真实值

本章小结

本章研究了随机变量序列的两种重要收敛模式，并以此为基础严格化了大数定律。

本章知识关系

- **知识上游：**随机变量的期望、方差，以及关键的**切比雪夫不等式**是证明弱大数定律的工具。特征函数则用于证明更一般的辛钦大数定律。
- **核心内容：**大数定律是本章核心，其本质是证明“**样本均值**”在不同条件下的收敛性。弱大数定律对应“**依概率收敛**”，强大数定律对应“**几乎必然收敛**”。
- **知识下游：**本章为后续的中心极限定理（描述收敛的分布）和更高阶的随机过程收敛理论打下基础。

本章核心结论

1. **基础版 WLLN:** 独立同分布 + 方差有限 $\implies$ 样本均值依概率收敛到期望。
2. **SLLN:** 独立同分布 + 期望有限 $\implies$ 样本均值几乎必然收敛到期望。
3. **收敛强度:** 几乎必然收敛强于依概率收敛。
4. **应用工具:** 切比雪夫不等式是证明 WLLN 和计算样本量的核心不等式。

必背公式

- **依概率收敛定义：**

$$\lim_{n \rightarrow \infty} P(|X_n - X| > \varepsilon) = 0$$

- **切比雪夫不等式：**

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}$$

- **马尔可夫不等式：**

$$P(X \geq \varepsilon) \leq \frac{E[X]}{\varepsilon} \quad (X \geq 0)$$

- **WLLN 结论：**

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

- **几乎必然收敛定义：**

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

- **SLLN 结论：**

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{a.s.} \mu$$

记忆 一句话记忆大数定律用切比雪夫不等式建立依概率收敛，用几乎必然收敛强化为强大数定律，它是频率逼近概率的数学基石。本章核心研究随机变量序列极限行为的两种基本模式：大数定律（LLN）与中心极限定理（CLT）。大数定律回答样本均值是否收敛到总体均值的问题，是统计估计与蒙特卡洛模拟的理论支柱；中心极限定理进一步刻画样本均值围绕总体均值的波动规律，阐明正态分布的普遍性。本章高频考点包括：依概率收敛与几乎必然收敛的区分、切比雪夫大数定律与辛钦大数定律的条件与结论、蒙特卡洛积分的原理与实现、依分布收敛的定义、林德伯格-莱维中心极限定理的标准化表达与近似计算、以及特征函数在定理证明中的桥梁作用。

设 $\{X_n\}$ 是随机变量序列， X 是一随机变量。若对任意 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P(|X_n - X| \geq \varepsilon) = 0$$

则称 $\{X_n\}$ 依概率收敛 (Convergence in Probability) 于 X ，记作 $X_n \xrightarrow{P} X$ 。[Lec14_2026_0603.pdf P14] 处给出直观：强大数定律下，任何一次实现，当 n 足够大时，样本均值都趋近于总体均值。

大数定律的核心机制是：独立同分布随机变量的算术平均，其方差随样本量 n 增大而趋于零，从而样本均值“稳定”在总体均值附近。

切比雪夫大数定律的推导须基于以下前提：

1. $\{X_n\}$ 相互独立（或至少两两不相关）。
2. 方差一致有界，即存在常数 $C > 0$ ，使得 $\text{Var}(X_i) \leq C$ 对所有 i 成立。在此条件下，对样本均值 $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ ，利用切比雪夫不等式：

$$P(|\bar{X}_n - E[\bar{X}_n]| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sum_{i=1}^n \text{Var}(X_i)}{n^2 \varepsilon^2} \leq \frac{C}{n \varepsilon^2} \rightarrow 0 \quad (n \rightarrow \infty)$$

故 $\bar{X}_n \xrightarrow{P} \mu$ ，其中 $\mu = E[\bar{X}_n]$ 。

辛钦大数定律去掉了方差有限的条件，但要求 $\{X_n\}$ 独立同分布且期望 μ 存在。其证明依赖特征函数在零点的可导性，结论同样是 $\bar{X}_n \xrightarrow{P} \mu$ 。

1. 判别使用哪条定律：

- 若题目明确“方差存在且一致有界”或只需基础证明，首先考虑切比雪夫大数定律。
- 若仅告知“独立同分布且期望存在”，则使用辛钦大数定律。

2. 构建目标统计量：通常是样本均值 $\bar{X}_n$ 或可化为样本均值的函数。

3. 应用大数定律结论：

- 切比雪夫：直接陈述 $\bar{X}_n \xrightarrow{P} E[\bar{X}_n]$ 。
- 辛钦：直接陈述 $\bar{X}_n \xrightarrow{P} \mu$ 。
- 更一般地，若 g 是连续函数，且 $\bar{X}_n \xrightarrow{P} \mu$ ，则 $g(\bar{X}_n) \xrightarrow{P} g(\mu)$ 。

4. 蒙特卡洛积分：利用大数定律将积分 $\int_a^b f(x)dx$ 转化为期望。

$$\int_a^b f(x)dx \approx (b-a) \cdot \frac{1}{n} \sum_{i=1}^n f(X_i)$$

其中 X_i 独立同分布于 $U(a, b)$ 。更一般的“投点法”中，若 $Y \sim U[0, c]$, $X \sim U[a, b]$, 则

$$\int_a^b f(x)dx \approx c(b-a) \cdot \frac{1}{n} \sum_{j=1}^n I_{\{Y_j \leq f(X_j)\}}$$

[Lec14_2026_0603.pdf P15]

易混概念	切比雪夫大数定律	辛钦大数定律
核心条件	方差一致有界，序列可仅不相关	独立同分布，期望存在（方差可不存在）
收敛模式	依概率收敛	依概率收敛
适用场景	保守，需要方差信息	广泛，是独立同分布场合的标准结论
证明工具	切比雪夫不等式	特征函数

- **混淆大数定律与中心极限定理：**大数定律描述均值本身的收敛（最终趋于一个常数），中心极限定理描述标准化后均值的分布的收敛（趋于正态分布）。切勿在需要计算概率或分位数时只答“由大数定律，均值等于 μ ”而忽略分布的随机波动。
- **蒙特卡洛积分：**务必乘上正确的缩放因子，如 $(b-a)$ 或 $c(b-a)$ ，遗漏此因子是高频计算错误。

例题

题目

需估计 $\theta = \int_0^2 e^x dx$ 的值。请设计一种蒙特卡洛方法，并写出估计量的表达式及算法的核心步骤。（来源：[Lec14_2026_0603.pdf P15] 原理改编）

思路

此题考查蒙特卡洛的“期望法”。实际应用中函数 $f(x) = e^x$ 在 $[0, 2]$ 上有界。可将积分写成均匀分布下的期望形式。核心是识别出 $X \sim U(0, 2)$ ，从而 $\theta = 2 \cdot E[e^X]$ 。

解答

1. 生成 n 个独立同分布的随机数 $X_1, X_2, \dots, X_n \sim U(0, 2)$ 。2. 计算 $Y_i = e^{X_i}$, $i = 1, \dots, n$ 。
3. 由辛钦大数定律，样本均值 $\frac{1}{n} \sum_{i=1}^n Y_i$ 依概率收敛于总体期望 $E[Y] = E[e^X]$ 。4. 因此， θ 的估计量可构造为：

$$\hat{\theta}_n = (2-0) \times \frac{1}{n} \sum_{i=1}^n e^{X_i} = \frac{2}{n} \sum_{i=1}^n e^{X_i}$$

当 n 充分大时， $\hat{\theta}_n$ 可准确逼近 θ 。

技巧

构建蒙特卡洛估计量时，永远先写出积分 = 区间长度 $\times E[g(X)]$ ，其中 X 是区间上的均匀分布，这是防止遗漏缩放因子的最稳健方法。

强大数定律 (SLLN) 与收敛模式辨析 重点

设 $\{X_n\}$ 是随机变量序列, X 是一随机变量。若

$$P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$$

则称 $\{X_n\}$ 几乎必然收敛 (Convergence Almost Surely) 于 X , 记作 $X_n \xrightarrow{a.s.} X$ 。

强大数定律 (SLLN) 指出: 若 $\{X_n\}$ 独立同分布且期望 μ 存在, 则样本均值 $\bar{X}_n \xrightarrow{a.s.} \mu$ 。[Lec14_2026_0603.pdf P14]

强大数定律与弱大数定律的根本区别在于收敛的强度:

- **依概率收敛 (弱):** 对任意 $\varepsilon > 0$, 事件 $|X_n - X| > \varepsilon$ 的概率趋于 0。它允许 X_n 与 X 在某些实现路径上存在持续偏差, 只要这种路径的集合概率为 0。
- **几乎必然收敛 (强):** 要求除去一个零测集外, 每条实现路径 $\{X_n(\omega)\}$ 最终都单调趋于 $X(\omega)$ 。这是逐点收敛的概率版本。[Lec14_2026_0603.pdf P14] 显然, 几乎必然收敛 $\Rightarrow$ 依概率收敛, 反之不真。强大数定律需更强的条件或更精细的证明工具, 但对独立同分布情形, 其成立条件与辛钦大数定律相同。

特征	依概率收敛 (弱)	几乎必然收敛 (强)
收敛方式	概率极限为 0	对几乎所有样本点逐点收敛
核心洞察	控制“大偏差”的概率	控制“整条路径”的波动
常用定理	切比雪夫 LLN, 辛钦 WLLN	柯尔莫哥洛夫 SLLN
应用场景	估计的相合性 (Consistency)	长时间运行的稳定性保证, 如蒙特卡洛模拟的必然有效性

- **错误理解强大数定律的“强”:** 并非指其结论数值更大, 而是指收敛模式 (几乎必然) 强于依概率收敛。
- **条件混淆:** 切比雪夫大数定律只保证弱收敛。辛钦大数定律通常指弱收敛, 但独立同分布下强大数定律同样成立 (柯尔莫哥洛夫)。

依分布收敛与中心极限定理 必背

设随机变量序列 $\{Y_n\}$ 和随机变量 Y 的分布函数分别为 $F_n(y)$ 和 $F(y)$ 。若对 $F(y)$ 的每一个连续点 y , 都有

$$\lim_{n \rightarrow \infty} F_n(y) = F(y)$$

则称 $\{Y_n\}$ 依分布收敛 (Convergence in Distribution) 于 Y , 记作 $Y_n \xrightarrow{D} Y$ 。[Lec14_2026_0603.pdf P23] 此定义巧妙连接了离散与连续分布, 不要求随机变量定义在同一个概率空间上, 只关注其分布函数的极限行为。

定理 2.1 (林德伯格-莱维中心极限定理, CLT) 设 $\{X_n\}$ 为独立同分布随机变量序列, 具有有限期望 μ 和方差 $\sigma^2 < \infty$ 。令 $S_n = \sum_{i=1}^n X_i$, 则其标准化形式依分布收敛于标准正态分布:

$$\frac{S_n - E[S_n]}{\sqrt{\text{Var}(S_n)}} = \frac{S_n - n\mu}{\sigma\sqrt{n}} \xrightarrow{D} N(0, 1)$$

[Lec14_2026_0603.pdf P24] 等价形式：样本均值 $\bar{X}_n = S_n/n$ 满足：

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$$

亦常记作 $\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N(0, \sigma^2)$ 。

定理证明思路 [Lec14_2026_0603.pdf P26]：

1. 标准化与归零：令 $Y_i = (X_i - \mu)/\sigma$ ，则 $E[Y_i] = 0, \text{Var}(Y_i) = 1$ 。待证结论等价于 $\frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i \xrightarrow{D} N(0, 1)$ 。
2. 特征函数法：计算 $\frac{1}{\sqrt{n}} \sum_{i=1}^n Y_i$ 的特征函数。

$$\phi_{\sum Y_i}(t) = \prod_{i=1}^n \phi_{Y_i}(t) = [\phi_Y(t)]^n$$

$$\phi_{\frac{1}{\sqrt{n}} \sum Y_i}(t) = \phi_Y\left(\frac{t}{\sqrt{n}}\right)^n$$

3. 泰勒展开：因 $E[Y] = 0, E[Y^2] = 1$ ，由特征函数的泰勒展开定理，有

$$\phi_Y(u) = 1 + iuE[Y] - \frac{1}{2}u^2E[Y^2] + o(u^2) = 1 - \frac{1}{2}u^2 + o(u^2)$$

4. 求极限：代入 $u = t/\sqrt{n}$ ，则

$$\phi_{\frac{1}{\sqrt{n}} \sum Y_i}(t) = \left[1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)\right]^n \longrightarrow e^{-t^2/2} \quad (n \rightarrow \infty)$$

极限函数 $e^{-t^2/2}$ 恰为标准正态分布的特征函数，且在 0 点连续。由特征函数的连续性定理，依分布收敛得证。[Lec14_2026_0603.pdf P26]

5. 识别题型：题目涉及“求样本均值或总和落在某区间的近似概率”、“确定最小样本量以满足给定精度”或“近似服从什么分布”。
6. 抽取信息：明确总体的分布类型（或一阶矩 μ 、二阶矩 σ^2 的值）、样本量 n 、所求的事件。
7. 标准化：将目标统计量 Z （如 $S_n, \bar{X}_n$ ）标准化为 $Z^* = \frac{Z - E[Z]}{\sqrt{\text{Var}(Z)}}$ 。
8. 应用 CLT 近似：声明 $Z^* \sim N(0, 1)$ 当 n 充分大。

- 概率计算： $P(a \leq \bar{X}_n \leq b) \approx \Phi\left(\frac{b-\mu}{\sigma/\sqrt{n}}\right) - \Phi\left(\frac{a-\mu}{\sigma/\sqrt{n}}\right)$ ，其中 Φ 为标准正态分布函数。
- 样本量确定：解方程 $P(|\bar{X}_n - \mu| < d) \approx 1 - \alpha$ ，得 $n \geq (z_{\alpha/2}\sigma/d)^2$ 。
- 忽略标准化：应用 CLT 时，必须使用标准化后的 $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ 去查正态分布表，错误使用 $\bar{X}_n$ 直接近似 $N(\mu, \sigma^2/n)$ 会导致查表时忘记标准化，是严重的概念错误。
- 滥用 CLT：CLT 要求独立同分布且方差 σ^2 有限。对于本身已近似对称的单峰分布， $n \geq 30$ 可能足够；对于高度偏斜或有厚尾的分布，可能需要更大的 n 。若总体方差不存在（如柯西分布），CLT 根本不适用。
- 近似时混淆离散与连续：若 X_i 是离散的，用正态连续分布近似其总和时需进行连续性校正 (continuity correction)，如将 $P(S_n \leq k)$ 近似为 $\Phi\left(\frac{k+0.5-n\mu}{\sqrt{n}\sigma}\right)$ 。课程已提及此点，是细节扣分高频地带。[Lec14_2026_0603.pdf P21, P29]

例题

题目

设 $X_1, \dots, X_{100}$ 独立同分布于泊松分布 $P(1)$ ，试利用中心极限定理，求 $\sum_{i=1}^{100} X_i > 110$ 的近似概率。 $(\Phi(1) \approx 0.8413)$ (来源：CLT 经典题改编)

思路

此为独立同分布随机变量总和的计算题。首先计算每个 X_i 的期望方差，对总和 S_n 进行标准化，再利用标准正态分布表计算概率。因 X_i 为离散分布，理论上可考虑连续性校正，但本题 $n=100$ 较大，可先按无校正演示基本步骤。

解答

1. 求矩：对 $P(1)$ ， $\mu = 1, \sigma^2 = 1$ 。2. 定义总和： $S_{100} = \sum_{i=1}^{100} X_i$ 。则 $E[S_{100}] = 100 \times 1 = 100$ ， $\text{Var}(S_{100}) = 100 \times 1 = 100$ 。3. 标准化与近似：由 CLT， $\frac{S_{100}-100}{\sqrt{100}} = \frac{S_{100}-100}{10} \sim N(0, 1)$ 。4. 计算概率：

$$P(S_{100} > 110) = P\left(\frac{S_{100} - 100}{10} > \frac{110 - 100}{10}\right) = P(Z > 1)$$

其中 $Z \sim N(0, 1)$ 。由对称性及 $\Phi(1) \approx 0.8413$ 得：

$$P(S_{100} > 110) \approx 1 - \Phi(1) = 1 - 0.8413 = 0.1587$$

技巧

应用中心极限定理的解题脉络极其固定：求矩 $\rightarrow$ 记总和/均值 $\rightarrow$ 减期望除以标准差 $\rightarrow$ 标准正态表查概率。遇到离散分布时，警惕是否需要连续性校正。

本章小结

本章知识关系

大数定律是基础，为统计量（如样本均值）成为其总体参数的“好”估计提供了理论依据，表现为样本均值的方差收敛到零。中心极限定理在此基础上更进一步，刻画了随机波动在极限下的分布形态—标准正态分布，从而使得我们可以在大样本下进行概率推断。二者都是关于“随机变量序列极限行为”的核心定理，前者分析一阶收敛性（本身），后者分析分布收敛性（标准化波动）。蒙特卡洛方法是大数定律的直接应用典范。

本章核心结论

1. 依概率收敛与几乎必然收敛：几乎必然收敛强于依概率收敛；两者均刻画“均值趋近于期望”。
2. 中心极限定理：独立同分布、方差有限的标准化样本均值，其极限分布为 $N(0, 1)$ 。这是正态分布具有“统治地位”的理论根源。
3. 定理应用：强/弱大数定律 $\rightarrow$ 蒙特卡洛积分。中心极限定理 $\rightarrow$ 大样本近似概率计算与样本量确定。

必背公式

- 切比雪夫大数定律条件: $\text{Var}(\bar{X}_n) \leq \frac{C}{n} \xrightarrow{n \rightarrow \infty} 0$
- 辛钦大数定律: $\bar{X}_n \xrightarrow{P} \mu$ (独立同分布且 μ 存在)
- 蒙特卡洛积分 (期望法): $\int_a^b f(x)dx \approx (b-a)\frac{1}{n} \sum_{i=1}^n f(X_i), \quad X_i \sim U[a, b]$
- CLT 标准化形式: $\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow{D} N(0, 1)$
- 总和近似分布: $S_n = \sum_{i=1}^n X_i \overset{\text{approx}}{\sim} N(n\mu, n\sigma^2)$

记忆 一句话记忆

大数定律确保“均值趋近于期望”，中心极限定理确保“标准化均值趋近于正态分布”。