

初等概率论

目录

一、考试范围	2
二、课程知识框架	2
三、各章详解	2
第 7 章随机向量函数的分布、次序统计量、p 分位数	2
本章总览	2
一、随机向量函数的分布	2
1. 一般情形 (CDF 法) 重点	2
2. 特殊情形: 和与差的分布 (卷积公式) 必背	3
3. 多个函数的联合密度 (雅可比变换法) 高频	4
4. 三大统计分布 必背	5
二、次序统计量	5
1. 次序统计量的定义与分布 高频	5
2. Beta 分布 重点	6
三、随机变量的 p 分位数	7
1. p 分位数的定义与性质 重点	7
2. 随机变量的生成 (反函数法) 高频	7
本章小结	8
第 8 章期望、方差、相关不等式	8
本章总览	8
一、期望的定义与计算 必背	8
1. 离散型与连续型期望	8
2. 随机变 (向) 量函数的期望 重点	9
3. 常见分布的期望汇总	11
二、期望的性质与应用 高频	11
1. 期望的线性性质与独立性	11
2. 最佳预测问题 高频	12
3. 高阶矩	12
三、方差与标准化 重点	12
1. 方差的定义与计算	12

2. 常见分布的方差汇总	13
3. 方差的性质与标准化	13
四、相关不等式 必背	14
1. Markov 与 Chebyshev 不等式	14
2. Cauchy-Schwarz 不等式 (内积不等式)	15
3. Jensen 不等式	15
本章小结	15
第 9 章条件期望、条件方差	16
本章总览	16
一、条件在事件上的条件期望 $E(X A)$ 必背	16
1. $E(X A)$ 的定义与计算定理	16
2. 全期望定理 重点	17
二、条件在随机变量上的条件期望 $E(X Y)$ 高频	18
1. $E(X Y)$ 的定义与计算	18
2. 重期望法则 必背	19
3. $E(X Y)$ 的性质 重点	20
4. 最佳预测问题 高频	21
三、条件方差 重点	21
1. 条件方差的定义与全方差法则	21
本章小结	23

> 本笔记由 [复习资料整理 Agent] 自动生成：入口无损读取全部原始资料，出口按考试优先原则整理。

一、考试范围

- 重点知识点 (Lecture 07_handout.pdf P61)
- 条件概率回顾 (本页需重点掌握) (Lecture 09_handout.pdf P8)

二、课程知识框架

初等概率论

- 第7章 随机向量函数的分布、次序统计量、p分位数
- 第8章 期望、方差、相关不等式
- 第9章 条件期望、条件方差

三、各章详解

第7章随机向量函数的分布、次序统计量、p分位数

本章总览

核心问题：如何求多维随机变量函数的分布？次序统计量有什么性质？p分位数如何定义与应用？高频考点排序：随机变量和/差/商的分布（卷积公式）> 雅可比变换法求联合密度 > 次序统计量的分布密度 > p分位数的定义与随机数生成。方法清单：CDF法（分布函数法）、卷积公式法、雅可比变换法（多对多变换）、次序统计量公式法、反函数法（生成随机数）。

一、随机向量函数的分布

1. 一般情形（CDF法）**重点**

定义 通过求 $Z = g(X, Y)$ 的累积分布函数（CDF） $F_Z(z) = \mathbb{P}(g(X, Y) \leq z)$ ，再求导得到概率密度函数（PDF） $f_Z(z)$ 的方法。原理与推导：

$$F_Z(z) = \mathbb{P}(g(X, Y) \leq z) = \iint_{g(x, y) \leq z} f(x, y) dx dy$$

对 $F_Z(z)$ 求导可得 $f_Z(z) = F'_Z(z)$ 。此方法适用于任何函数 g ，但积分区域的确定和计算可能较复杂。**解题步骤**

1. 写出 Z 的 CDF 定义 $\mathbb{P}(g(X, Y) \leq z)$ 。
2. 将概率转化为联合密度在区域 $\{(x, y) \mid g(x, y) \leq z\}$ 上的二重积分。
3. 计算积分，得到 $F_Z(z)$ 的分段表达式。

4. 对 $F_Z(z)$ 求导得到 $f_Z(z)$ 。易错点 积分区域随 z 的变化而改变，必须分区间讨论；求导时注意分段点处的连续性。

例题

题目

设 (X, Y) 为单位正方形上的均匀分布， X, Y 独立。求 $Z = Y/X$ 的概率密度函数。[Lecture 07_handout.pdf P10]

思路

采用 CDF 法。先求 $F_Z(z) = \mathbb{P}(Y/X \leq z)$ ，由于 $X, Y \in (0, 1)$ ，需根据 z 与 1 的关系划分积分区域。

解答

当 $0 \leq z \leq 1$ 时，积分区域为 $0 < x < 1, 0 < y < zx$ ，此时：

$$F_Z(z) = \int_0^1 \int_0^{zx} 1 \, dy \, dx = \int_0^1 zx \, dx = \frac{z}{2}$$

当 $z > 1$ 时，积分区域为 $0 < x < 1/z, 0 < y < 1$ 与 $1/z < x < 1, 0 < y < zx$ 的并集，或直接计算补集：

$$F_Z(z) = 1 - \mathbb{P}(Y/X > z) = 1 - \int_0^1 \int_{zx}^1 1 \, dy \, dx = 1 - \int_0^1 (1 - zx) \, dx = 1 - \frac{1}{2z}$$

当 $z < 0$ 时， $F_Z(z) = 0$ 。求导得密度函数：

$$f_Z(z) = \begin{cases} 1/2, & 0 \leq z \leq 1 \\ 1/(2z^2), & z > 1 \\ 0, & \text{others} \end{cases}$$

技巧

求商的分布时，利用 CDF 法画图确定积分限最稳妥；当 $z > 1$ 时计算补集（对立事件）积分更简便。

2. 特殊情形：和与差的分布（卷积公式）必背

定义 设 (X, Y) 有联合密度 $f(x, y)$ ，则 $Z = X + Y$ 的密度函数为：

$$f_Z(z) = \int_{-\infty}^{\infty} f(x, z-x) \, dx \quad (1-1)$$

若 X, Y 独立，则有卷积公式：

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) \, dx \quad (1-2)$$

对于差 $V = X - Y$ ，密度函数为：

$$f_V(v) = \int_{-\infty}^{\infty} f(x, x-v) \, dx \quad (1-3)$$

独立时为 $f_V(v) = \int_{-\infty}^{\infty} f_X(x)f_Y(x-v)dx$ 。原理与推导：利用 CDF 法， $\mathbb{P}(a < X+Y \leq b) = \iint_{a < x+y \leq b} f(x,y)dx dy$ ，通过变量替换 $y = z - x$ 并交换积分次序求导可得。 **解题步骤**

1. 判断独立性，写出卷积公式。
2. 确定积分变量的有效范围（使得被积函数非零）。
3. 计算积分，得到分段密度函数。 **易错点** 积分上下限的确定，需结合 $f_X(x) \neq 0$ 和 $f_Y(z-x) \neq 0$ 的交集；差分布公式中代入的是 $x-v$ 而非 $v-x$ 。

例题

题目

设 X, Y 独立且都服从 $\mathcal{U}(0, 1)$ 。求 $Z = X + Y$ 的概率密度。 [Lecture 07_handout.pdf P16]

思路

使用独立随机变量和的卷积公式。被积函数为 $f_X(x)f_Y(z-x) = I_{\{0 < x < 1\}}I_{\{0 < z-x < 1\}}$ ，需根据 z 的范围确定 x 的积分限。

解答

$$f_Z(z) = \int_{-\infty}^{\infty} I_{\{0 < x < 1\}}I_{\{0 < z-x < 1\}} dx$$

由 $0 < x < 1$ 且 $z-1 < x < z$ ：当 $0 \leq z \leq 1$ 时， $x \in (0, z)$ ，积分得 z ；当 $1 < z \leq 2$ 时， $x \in (z-1, 1)$ ，积分得 $2-z$ 。

$$f_Z(z) = \begin{cases} z, & 0 \leq z \leq 1 \\ 2-z, & 1 < z \leq 2 \\ 0, & \text{others} \end{cases}$$

技巧

两个均匀分布之和呈三角形分布。求解时通过数轴画图找交集区间是关键。

3. 多个函数的联合密度（雅可比变换法） **高频**

定义 设 (X, Y) 有联合密度 $f(x, y)$, $U = u(X, Y)$, $V = v(X, Y)$ 。若存在逆变换 $x_i = x_i(u, v)$, $y_i = y_i(u, v)$ ，则 (U, V) 的联合密度为：

$$g(u, v) = \sum_{i=1}^n f(x_i(u, v), y_i(u, v)) |J_i| \quad (1-4)$$

其中 $J_i = \frac{\partial(x_i, y_i)}{\partial(u, v)}$ 为雅可比行列式。原理与推导：基于多重积分的变量替换定理。要求逆映射可微且雅可比行列式不为 0。 **解题步骤**

1. 写出正变换 $U = u(X, Y)$, $V = v(X, Y)$ 及其逆变换。
2. 求雅可比行列式的绝对值 $|J| = \left| \frac{\partial(x, y)}{\partial(u, v)} \right|$ 。

- 代入公式 $g(u, v) = f(x(u, v), y(u, v))|J|$ 。
- 确定 (u, v) 的取值范围。易错点 雅可比行列式求错（常将 $\frac{\partial(x, y)}{\partial(u, v)}$ 算成其倒数）；多解情况（如极坐标变换）需将所有解对应的密度相加；忽略取值范围的变换。

例题

题目

设 X, Y 独立且服从 $\mathcal{N}(0, 1)$, (R, Θ) 由极坐标变换 $X = R \cos \Theta, Y = R \sin \Theta$ 决定, 求 (R, Θ) 的联合密度。[Lecture 07_handout.pdf P28]

思路

二维到二维的变换, 使用雅可比变换法。正变换已知, 直接求偏导计算雅可比行列式。

解答

逆变换为 $x = r \cos \theta, y = r \sin \theta$ 。雅可比行列式为:

$$J = \frac{\partial(x, y)}{\partial(r, \theta)} = \begin{vmatrix} \cos \theta & -r \sin \theta \\ \sin \theta & r \cos \theta \end{vmatrix} = r \cos^2 \theta + r \sin^2 \theta = r$$

(X, Y) 联合密度 $f(x, y) = \frac{1}{2\pi} \exp\left(-\frac{x^2 + y^2}{2}\right)$ 。代入得:

$$g(r, \theta) = \frac{1}{2\pi} \exp\left(-\frac{r^2 \cos^2 \theta + r^2 \sin^2 \theta}{2}\right) |r| = \frac{1}{2\pi} r e^{-r^2/2}, \quad r > 0, \theta \in [0, 2\pi)$$

技巧

极坐标变换的雅可比行列式 $|J| = r$ 是常用结论, 需牢记。结果可分解为 R (Rayleigh 分布) 和 Θ (均匀分布) 的乘积, 说明二者独立。

4. 三大统计分布 必背

定义 由标准正态分布独立变量构造的三大分布:

- 卡方分布: 设 $Z_j \sim \mathcal{N}(0, 1)$ 独立, $X = \sum_{j=1}^n Z_j^2 \sim \chi_n^2$ 。且 $\chi_n^2 = \Gamma(n/2, 1/2)$ 。
- t 分布: 设 $Z \sim \mathcal{N}(0, 1)$, $X \sim \chi_n^2$ 独立, $T = \frac{Z}{\sqrt{X/n}} \sim t_n$ 。当 $n = 1$ 时为 Cauchy 分布。
- F 分布: 设 $X_j \sim \mathcal{N}(0, 1), Y_j \sim \mathcal{N}(0, 1)$ 独立, $F = \frac{\sum_{i=1}^m X_i^2/m}{\sum_{i=1}^n Y_i^2/n} \sim F(m, n)$ 。原理与推导: 均可看作随机向量函数的分布, 通过雅可比变换法或 CDF 法推导其密度函数。易错点 t 分布的自由度在分母根号内; F 分布的分子分母自由度位置不能颠倒。

二、次序统计量

1. 次序统计量的定义与分布 高频

定义 设 $X_1, \dots, X_n$ 为 i.i.d. 变量, 将它们从小到大排列得到 $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$, 称 $X_{(k)}$ 为第 k 个次序统计量。原理与推导: 利用多项分布思想, n 个样本中有 $k-1$ 个落在 x 左侧, 1 个

落在 dx 内, $n-k$ 个落在 x 右侧。 **解题步骤**

1. 联合密度: $(X_{(1)}, \dots, X_{(n)})$ 的联合密度为

$$g(x_1, \dots, x_n) = n! \prod_{i=1}^n f(x_i), \quad x_1 < \dots < x_n \quad (2-1)$$

2. 边缘密度: 第 k 个次序统计量 $X_{(k)}$ 的密度为

$$g_k(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} f(x) \quad (2-2)$$

3. 多个次序统计量联合密度: 对于 $k_1 < k_2$, $(X_{(k_1)}, X_{(k_2)})$ 的联合密度为

$$g(x_{k_1}, x_{k_2}) = \frac{n!}{(k_1-1)!(k_2-k_1-1)!(n-k_2)!} [F(x_{k_1})]^{k_1-1} [F(x_{k_2})-F(x_{k_1})]^{k_2-k_1-1} [1-F(x_{k_2})]^{n-k_2} f(x_{k_1}) f(x_{k_2}) \quad (2-3)$$

易错点 忘记组合数系数 (阶乘项); 幂次弄错, 特别是 $1-F(x)$ 的幂次是 $n-k$ 而非 $n-k-1$ (单变量密度)。

例题

题目

某教学楼原来每个教室有 4 只灯泡, 新装修后有 24 只灯泡。设灯泡寿命 $X_i \sim \mathcal{E}(\lambda)$ 独立。解释为何管理员觉得灯泡更容易坏。 [Lecture 07_handout.pdf P40]

思路

灯泡更容易坏体现在“第一只灯泡烧坏的时间”变短, 即求最小值 $X_{(1)}$ 的分布。利用次序统计量公式 ($k=1$)。

解答

装修前 $n=4$, 装修后 $n=24$ 。第一只烧坏的时间为 $X_{(1)}$ 。由公式 (2-2), 当 $k=1$ 时, $g_1(x) = n[1-F(x)]^{n-1}f(x)$ 。对于指数分布 $\mathcal{E}(\lambda)$, $F(x) = 1 - e^{-\lambda x}$, $f(x) = \lambda e^{-\lambda x}$ 。

$$g_1(x) = n(e^{-\lambda x})^{n-1} \lambda e^{-\lambda x} = n\lambda e^{-n\lambda x}$$

即 $X_{(1)} \sim \mathcal{E}(n\lambda)$ 。装修前 $X_{(1)} \sim \mathcal{E}(4\lambda)$, 装修后 $Y_{(1)} \sim \mathcal{E}(24\lambda)$ 。由于 $24\lambda > 4\lambda$, 新分布的期望更小 ($1/24\lambda < 1/4\lambda$), 所以更容易坏。

技巧

n 个独立指数分布变量的最小值仍服从指数分布, 且参数相加 (无记忆性推导)。

2. Beta 分布 **重点**

定义 若 $X \sim \text{Beta}(\alpha, \beta)$, 其密度为 $f(x) = \frac{1}{B(\alpha, \beta)} x^{\alpha-1} (1-x)^{\beta-1}$, $0 < x < 1$ 。原理与推导: Beta 分布可看作均匀分布 $\mathcal{U}(0, 1)$ 的次序统计量的分布。若 $X_i \sim \mathcal{U}(0, 1)$, 则 $F(x) = x$, $f(x) = 1$ 。代入次序统计量公式 (2-2):

$$g_k(x) = \frac{n!}{(k-1)!(n-k)!} x^{k-1} (1-x)^{n-k}$$

这正是 $Beta(k, n-k+1)$ 分布。**易错点** 混淆参数对应关系, 第 k 个次序统计量对应 $Beta(k, n-k+1)$, 而非 $Beta(k, n-k)$ 。

三、随机变量的 p 分位数

1. p 分位数的定义与性质 **重点**

定义 对 $p \in (0, 1)$, 随机变量 X 的 p 分位数定义为:

$$F^{-1}(p) = \inf\{x : F(x) \geq p\} \quad (3-1)$$

直观定义: 满足 $\mathbb{P}(X \leq x) \geq p$ 且 $\mathbb{P}(X \geq x) \geq 1-p$ 的 x 。当 $p = 1/2$ 时称为中位数。原理与推导: 由于 CDF 可能不连续或非严格单调, 直观定义可能不唯一, 因此采用下确界定义保证唯一性。

易错点 分位数的两个不等号方向 ($\geq p$ 和 $\geq 1-p$); 性质 $F^{-1}(F(x)) \leq x$ 和 $F(F^{-1}(p)) \geq p$ 的不等号方向易混。

性质	表达式	说明
单调性	$F^{-1}(p)$ 单调非降	p 越大, 分位数越大
复合不等式 1	$F^{-1}(F(x)) \leq x$	先求 CDF 再求分位数, 可能变小
复合不等式 2	$F(F^{-1}(p)) \geq p$	先求分位数再求 CDF, 可能变大
等价条件	$F^{-1}(p) \leq t \iff p \leq F(t)$	核心判定性质
连续性	$F^{-1}(p)$ 左连续	CDF 是右连续, 其逆是左连续
连续分布特例	若 F 连续, $F(F^{-1}(p)) = p$	连续且严格单调时互为反函数

2. 随机变量的生成 (反函数法) **高频**

定义 定理: 设 $X \sim \mathcal{U}(0, 1)$, $F(x)$ 是连续分布函数, 则 $Y = F^{-1}(X) \sim F$ 。原理与推导:

$$F_Y(y) = \mathbb{P}(F^{-1}(X) \leq y) = \mathbb{P}(X \leq F(y)) = F(y)$$

解题步骤

1. 令 $F(Y) = U$, 其中 $U \sim \mathcal{U}(0, 1)$ 。
2. 解方程求出 $Y = F^{-1}(U)$ 。**易错点** 对于离散分布, 需分段处理; 对于连续分布, 若 F 不可逆, 需利用分位数定义构造。

例题

题目

设易生成服从均匀分布的随机变量 $U \sim \mathcal{U}(0, 1)$, 如何生成服从指数分布 $\mathcal{E}(\lambda)$ 的随机变量?
[Lecture 07_handout.pdf P53]

思路

使用反函数法。先写出目标分布的 CDF, 求其反函数, 代入均匀随机数。

解答

指数分布 $\mathcal{E}(\lambda)$ 的 CDF 为 $F(x) = 1 - e^{-\lambda x}$ ($x \geq 0$)。令 $U = F(Y) = 1 - e^{-\lambda Y}$ ，解得：

$$e^{-\lambda Y} = 1 - U \implies Y = -\frac{1}{\lambda} \ln(1 - U)$$

由于 $U \sim \mathcal{U}(0, 1)$ ，则 $1 - U \sim \mathcal{U}(0, 1)$ ，因此也可简化为 $Y = -\frac{1}{\lambda} \ln U$ 。

技巧

反函数法生成随机数时，若 $1 - U$ 与 U 同分布，可利用此性质简化公式，避免对数计算时出现负数报错。

本章小结

本章知识关系：随机向量函数的分布是第 2 章单变量函数分布的多维推广，其中雅可比变换法是核心工具；次序统计量是随机向量函数（排序函数）的重要应用，并引出了 Beta 分布；p 分位数是分布函数的逆运算，其核心应用是随机数生成。本章核心结论：求多维函数分布首选 CDF 法或雅可比变换；独立变量和的分布为卷积；次序统计量密度由组合数与 CDF 的幂次乘积构成；连续分布的随机数可通过 $F^{-1}(U)$ 生成。必背公式：

1. 卷积公式： $f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z - x) dx$
2. 雅可比变换： $g(u, v) = f(x(u, v), y(u, v)) \left| \frac{\partial(x, y)}{\partial(u, v)} \right|$
3. 次序统计量密度： $g_k(x) = \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1 - F(x)]^{n-k} f(x)$
4. 随机数生成： $Y = F^{-1}(U) \sim F$ 记忆 函数分布靠变换（雅可比），和求卷积，序求组合（次序统计量），逆生随机数（分位数）。

第 8 章期望、方差、相关不等式

本章总览

- 核心问题：如何度量随机变量的“中心位置”（期望）与“离散程度”（方差）？如何利用不等式对概率进行放缩估计？
- 高频考点排序：1. 期望与方差的性质计算（尤其是线性性与独立性）；2. 随机变量函数的期望计算；3. 三大不等式（Markov/Chebyshev, Cauchy-Schwarz, Jensen）的证明与应用；4. 最佳预测问题（均方误差意义下期望的最优性）；5. 常见分布的期望与方差推导。
- 方法清单：定义法（级数/积分求期望）、利用性质化简（拆分随机变量、示性函数）、归一化法与对称性法、配方法与二次型法（证明不等式）。

一、期望的定义与计算 必背

1. 离散型与连续型期望

定义

- 离散型：设 X 有概率分布 $\mathbb{P}(X = x_j), j = 1, 2, \dots$ ，若 $\sum_{j=1}^{\infty} |x_j| \mathbb{P}(X = x_j) < +\infty$ ，则 $E(X) = \sum_{j=1}^{\infty} x_j \mathbb{P}(X = x_j)$ 。
- 连续型：设 X 有概率密度 $f(x)$ ，若 $\int_{-\infty}^{\infty} |x| f(x) dx < +\infty$ ，则 $E(X) = \int_{-\infty}^{\infty} x f(x) dx$ 。
- 物理意义：质心（分布的重心）。

原理与推导：期望存在的必要条件是绝对收敛。若级数或积分不绝对收敛，则期望不存在（如 Cauchy 分布）。

解题步骤

1. 确认随机变量类型（离散/连续）。
2. 写出其 PMF 或 PDF。
3. 代入定义式求和或积分。常用技巧：利用归一化性质（凑概率密度的积分等于 1）、对称性（奇函数在对称区间积分为 0）、阶乘错位法（针对二项、Poisson 等）。

易错点

- 计算时未验证绝对收敛，导致错误结论（如发散级数条件收敛）。
- 离散型求和时下标错位（如二项分布 j 从 0 开始，但提取 j 后需从 1 开始）。

例题**题目**

甲、乙对赌，先赢满 5 局获 100 金币。甲赢 4 局，乙赢 3 局时中断，如何分配赌金？[Lecture08_handout.pdf P6]

思路

计算甲、乙最终获胜的概率，将赌金视为随机变量，求期望收益。

解答

甲赢满 5 局需再赢 1 局，乙需再赢 2 局。可能后续情景：甲直接赢（概率 $1/2$ ），或乙赢一局后甲赢（概率 $1/4$ ）。甲获胜概率 $3/4$ ，乙获胜概率 $1/4$ 。甲收益 $X = \{100, 0\}$ ，概率 $\{3/4, 1/4\}$ 。

$$E(X) = 100 \times \frac{3}{4} + 0 \times \frac{1}{4} = 75$$

同理 $E(X) = 25$ 。按 $3:1$ 分配。

技巧

期望的本质是加权平均，解决博弈分配问题直接计算预期收益。

2. 随机变（向）量函数的期望 **重点**

定义 设 $\mathbf{X} = (X_1, \dots, X_n)$ 是随机向量，若实函数 $g(\mathbf{x})$ 使得 $\int_{\mathbb{R}^n} |g(\mathbf{x})| dF(\mathbf{x}) < \infty$ ，则 $Y = g(\mathbf{X})$ 的期望为：

$$E(g(\mathbf{X})) = \int_{\mathbb{R}^n} g(\mathbf{x}) dF(\mathbf{x})$$

原理与推导：该定理（定理 2.1）避免了“先求 $Y = g(X)$ 的分布，再求 $E(Y)$ ”的繁琐过程，可直接用 X 的分布计算 $g(X)$ 的期望。

解题步骤

1. 确定原随机变量 X 或 $\mathbf{X}$ 的分布。
2. 将目标函数 $g(X)$ 直接代入期望定义式。
3. 利用微积分技巧（换元法、分部积分）或期望性质求解。

易错点

- 误认为 $E(g(X)) = g(E(X))$ （除非 g 是线性函数或特殊情形）。
- 多维情况下积分区域出错。

例题**题目**

设 $X \sim U(0, \pi/2)$ ，计算 $E(\cos X)$ 。[Lecture08_handout.pdf P25]

思路

直接利用随机变量函数的期望公式，避免求 $\cos X$ 的密度函数。

解答

X 的密度为 $f(x) = \frac{2}{\pi} I_{(0, \pi/2)}(x)$ 。

$$E(\cos X) = \int_{-\infty}^{\infty} \cos x f(x) dx = \frac{2}{\pi} \int_0^{\pi/2} \cos x dx = \frac{2}{\pi} [\sin x]_0^{\pi/2} = \frac{2}{\pi}$$

技巧

求随机变量函数的期望时，**永远不要**先去求新变量的分布，直接带原密度积分！

3. 常见分布的期望汇总

分布名称	符号	期望 $E(X)$	推导关键技巧
两点分布	$B(1, p)$	p	定义法
二项分布	$B(n, p)$	np	阶乘错位 $j\binom{n}{j} = n\binom{n-1}{j-1}$, 归一化
Poisson 分布	$\mathcal{P}(\lambda)$	λ	阶乘错位 $k/k! = 1/(k-1)!$, 归一化
几何分布	$G(p)$	$1/p$	错位相减或求导
均匀分布	$U(a, b)$	$(a + b)/2$	对称性/质心
指数分布	$\varepsilon(\lambda)$	$1/\lambda$	分部积分、归一化
Gamma 分布	$\Gamma(\alpha, \beta)$	α/β	换元 $t = \beta x$, 利用 $\Gamma(\alpha + 1) = \alpha\Gamma(\alpha)$
正态分布	$\mathcal{N}(\mu, \sigma^2)$	μ	对称性 (奇函数积分为 0)

二、期望的性质与应用 高频

1. 期望的线性性质与独立性

定义

- 1. $E(C) = C$
- 2. $E(aX + bY) = aE(X) + bE(Y)$ (线性性, 无需独立条件)
- 3. 若 X, Y 独立, 则 $E(XY) = E(X)E(Y)$
- 4. $X \leq Y$ a.s. $\Rightarrow E(X) \leq E(Y)$

原理与推导: 线性性是期望最核心的性质, 由积分/求和的线性性直接给出。独立性乘法法则由联合密度分解为边缘密度乘积证得。

解题步骤 对于复杂随机变量 X , 常将其拆分为简单随机变量之和: $X = X_1 + \cdots + X_n$, 利用 $E(X) = \sum E(X_i)$ 简化计算 (如超几何分布、配对问题)。

易错点

- 混淆独立与不相关: $E(XY) = E(X)E(Y)$ 仅要求不相关, 但通常用独立性来保证此式成立。
- 误认为 $E(X/Y) = E(X)/E(Y)$ 。

例题

题目

N 件产品中有 M 件正品, 无放回任取 n 件, 期望抽到几件正品? [Lecture08_handout.pdf P29]

思路

超几何分布直接求期望极难。引入示性函数 X_k 表示第 k 次是否抽到正品，利用线性性求解。

解答

记 X_k 为第 k 次抽到正品数 (0 或 1)。 $X = X_1 + \cdots + X_n$ 。无论之前抽什么，第 k 次抽到正品的概率均为 M/N (抓阄模型)，故 $E(X_k) = M/N$ 。

$$E(X) = \sum_{k=1}^n E(X_k) = n \frac{M}{N}$$

技巧

复杂计数问题通过“示性函数 + 线性性”拆解，可避开复杂的联合分布。

2. 最佳预测问题 高频

定义 在均方误差 (MSE) 意义下，寻找常数 c 使得 $E((X - c)^2)$ 最小。

$$E(X) = \arg \min_{c \in \mathbb{R}} E((X - c)^2)$$

原理与推导：

$$E((X - c)^2) = E((X - E(X) + E(X) - c)^2) = \text{Var}(X) + (E(X) - c)^2 \geq \text{Var}(X)$$

当且仅当 $c = E(X)$ 时等号成立。

易错点

- 误认为中位数是 MSE 最小的预测。中位数是绝对误差 $E(|X - c|)$ 最小的预测。

3. 高阶矩

定义

- m 阶原点矩： $E(X^m)$
- m 阶中心矩： $E((X - E(X))^m)$
- 偏度： $E\left[\frac{(X - \mu)^3}{\sigma^3}\right]$ (衡量不对称性)
- 峰度： $E\left[\frac{(X - \mu)^4}{\sigma^4}\right] - 3$ (衡量尾部厚度，减 3 是为了使正态分布峰度为 0)

三、方差与标准化 重点

1. 方差的定义与计算

定义 设 $E(X) = \mu$ 有限，称 $\text{Var}(X) = E((X - \mu)^2)$ 为 X 的方差，记作 σ_X^2 。

原理与推导：方差表示 X 在期望附近的集中程度。计算公式推导：

$$\text{Var}(X) = E(X^2 - 2\mu X + \mu^2) = E(X^2) - 2\mu E(X) + \mu^2 = E(X^2) - (E(X))^2$$

解题步骤

1. 先求 $E(X)$ 。
2. 再求 $E(X^2)$ (注意: $E(X^2)$ 必须用 X^2 的分布或函数期望公式求, 不能用 $(E(X))^2$)。
3. $Var(X) = E(X^2) - (E(X))^2$ 。

易错点

- 混淆 $E(X^2)$ 与 $(E(X))^2$ 。
- 计算离散分布方差时, 求 $E(X^2)$ 常用技巧 $X^2 = X(X-1) + X$, 以利用阶乘错位。

2. 常见分布的方差汇总

分布	$E(X^2)$	$Var(X)$
$B(1, p)$	p	$p(1-p)$
$B(n, p)$	-	$np(1-p)$
$P(\lambda)$	$\lambda^2 + \lambda$	λ
$G(p)$	$2q/p^2 + 1/p$	q/p^2 ($q = 1-p$)
$U(a, b)$	$(b^3 - a^3)/(3(b-a))$	$(b-a)^2/12$
$\varepsilon(\lambda)$	$2/\lambda^2$	$1/\lambda^2$
$\Gamma(\alpha, \beta)$	$\alpha(\alpha+1)/\beta^2$	α/β^2
$\mathcal{N}(\mu, \sigma^2)$	$\mu^2 + \sigma^2$	σ^2

3. 方差的性质与标准化**定义**

1. $Var(aX + b) = a^2 Var(X)$
2. $Var(X) \leq E((X-c)^2), \forall c$
3. $Var(X) = 0 \iff X = E(X)$ a.s.
4. **独立可加性:** 若 $X_1, \dots, X_n$ 相互独立, $Var(\sum X_k) = \sum Var(X_k)$

标准化: 令 $Y = \frac{X-E(X)}{\sqrt{Var(X)}}$, 则 $E(Y) = 0, Var(Y) = 1$ 。

易错点

- 方差不具有一般可加性! $Var(X+Y) = Var(X) + Var(Y) + 2Cov(X, Y)$, 只有独立 (或不相关) 时协方差项才为 0。

例题

题目

(配对问题) n 封信随机装入 n 个信封, 记 X 为匹配正确的封数。求 $E(X)$ 和 $Var(X)$ 。
[Lecture08_handout.pdf P49]

思路

利用示性函数 X_k 表示第 k 封信是否匹配, $X = \sum X_k$ 。注意 X_k 之间不独立, 求方差需展开协方差。

解答

$X_k \sim B(1, 1/n)$, $E(X) = \sum E(X_k) = n(1/n) = 1$ 。 $X_k X_j$ 表示第 k 和第 j 封都匹配, 其概率为 $\frac{1}{n(n-1)}$ 。

$$E(X_k X_j) = \frac{1}{n(n-1)}$$

$$Var(X) = Var(\sum X_k) = \sum Var(X_k) + 2 \sum_{k < j} Cov(X_k, X_j)$$

$$Cov(X_k, X_j) = E(X_k X_j) - E(X_k)E(X_j) = \frac{1}{n(n-1)} - \frac{1}{n^2} = \frac{1}{n^2(n-1)}$$

$$Var(X) = n \cdot \frac{n-1}{n^2} + 2 \binom{n}{2} \frac{1}{n^2(n-1)} = \frac{n-1}{n} + \frac{1}{n} = 1$$

技巧

求和变量的方差, 若不独立必须计算两两协方差; 利用 $X_i X_j$ 的物理意义求混合期望。

四、相关不等式 必背

1. Markov 与 Chebyshev 不等式

定义

- Markov 不等式: 对非负随机变量 X 和 $\varepsilon > 0, \alpha > 0$,

$$\mathbb{P}(X \geq \varepsilon) \leq \frac{E(X^\alpha)}{\varepsilon^\alpha}$$

- Chebyshev 不等式: 对任意随机变量 X 和 $\varepsilon > 0$,

$$\mathbb{P}(|X - E(X)| \geq \varepsilon) \leq \frac{Var(X)}{\varepsilon^2}$$

原理与推导: Markov 不等式证明 (以 $\alpha = 1$ 为例):

$$E(X) = \int_0^\infty x f(x) dx \geq \int_\varepsilon^\infty x f(x) dx \geq \int_\varepsilon^\infty \varepsilon f(x) dx = \varepsilon \mathbb{P}(X \geq \varepsilon)$$

Chebyshev 不等式是 Markov 不等式的直接推论, 令 $Y = (X - E(X))^2$, 则 $\mathbb{P}(|X - E(X)| \geq \varepsilon) = \mathbb{P}(Y \geq \varepsilon^2) \leq \frac{E(Y)}{\varepsilon^2} = \frac{Var(X)}{\varepsilon^2}$ 。

易错点

- Markov 不等式要求 X 非负。
- Chebyshev 给出的是双侧尾概率界限。

2. Cauchy-Schwarz 不等式 (内积不等式)

定义 若 $E(X^2) < \infty, E(Y^2) < \infty$, 则

$$|E(XY)| \leq \sqrt{E(X^2)E(Y^2)}$$

等号成立当且仅当存在不全为 0 的 a, b 使得 $aX + bY = 0$ a.s. (即 X, Y 线性相关)。

原理与推导: 构造二次型 $E((aX + bY)^2) \geq 0$, 展开为关于 a, b 的非负定二次型, 其判别式 $\Delta \leq 0$ 即得证。

3. Jensen 不等式

定义 若 ψ 是凸函数, 且 X 和 $\psi(X)$ 期望有限, 则

$$\psi(E(X)) \leq E(\psi(X))$$

若 ψ 严格凸, 等号成立当且仅当 $X = E(X)$ a.s. (即 X 是常数)。

原理与推导: 凸函数定义: 对任意点 a , 存在次梯度 c 使得 $\psi(b) - \psi(a) \geq c(b - a)$ 。令 $a = E(X), b = X$, 两边取期望即证。

易错点

- 方向混淆: 凸函数是 $\psi(E(X)) \leq E(\psi(X))$, 凹函数反之。
- 忘记验证等号成立条件。

本章小结

- **本章知识关系:** 期望是概率分布的质心, 方差衡量围绕质心的离散度。期望的线性性是计算复杂随机变量的利器, 而方差则依赖独立性展现可加性。三大不等式利用期望和方差对尾部概率进行理论上的界估计, 是理论推导的基石。
- **本章核心结论:** 期望是 MSE 意义下的最佳预测; 方差等于平方的期望减去期望的平方; 独立变量和的方差等于方差的和。
- **必背公式:**

$$- \text{Var}(X) = E(X^2) - (E(X))^2$$

$$- \text{Var}(aX + b) = a^2 \text{Var}(X)$$

$$- \text{Markov: } \mathbb{P}(X \geq \varepsilon) \leq E(X)/\varepsilon$$

$$- \text{Chebyshev: } \mathbb{P}(|X - \mu| \geq \varepsilon) \leq \sigma^2/\varepsilon^2$$

$$- \text{C-S: } [E(XY)]^2 \leq E(X^2)E(Y^2)$$

$$- \text{Jensen: } \psi(E(X)) \leq E(\psi(X)) \text{ } (\psi \text{ 为凸函数})$$

- **记忆:** 期望是质心最佳预测, 方差是平方期望减期望平方; 独立才能方差相加; 凸函数期望大于等于期望的函数。

第 9 章条件期望、条件方差

本章总览

- **核心问题：**如何在给定部分信息（事件 A 或随机变量 Y ）时，重新评估随机变量 X 的期望与方差？如何利用条件期望简化复杂期望的计算？
- **高频考点排序：**1. 重期望法则 $E[E(X|Y)] = E(X)$ 的应用；2. 全方差公式 $var(X) = E[var(X|Y)] + var(E(X|Y))$ 的应用；3. 条件期望的性质（特别是 $E(h(Y)g(X)|Y) = h(Y)E(g(X)|Y)$ ）；4. 二元正态分布的条件期望计算。
- **方法清单：**遇到求复杂随机变量期望/方差时，优先寻找合适的条件随机变量 Y ，先求条件期望/方差，再求期望；遇到条件期望计算，先视条件 $Y = y$ 为常数求 $E(X|Y = y)$ ，再将 y 替换为 Y 。

一、条件在事件上的条件期望 $E(X|A)$ **必背**1. $E(X|A)$ 的定义与计算定理

定义 给定事件 A 发生（且 $P(A) > 0$ ）时，随机变量 X 的条件期望 $E(X|A)$ 定义为在条件分布下的期望。

- 离散型： $E(X|A) = \sum_{i=1}^{\infty} x_i P(X = x_i|A)$
- 连续型： $E(X|A) = \int_{-\infty}^{\infty} x f_{X|A}(x) dx$

原理与推导：在实际计算中，常利用以下定理将条件期望转化为无条件期望与指示函数乘积的期望，从而避免求条件分布：

$$E(X|A) = \frac{E[XI_A]}{P(A)} \quad (9-1)$$

其中 I_A 是事件 A 的指示函数。该公式适用于 X 为任意随机变量（离散或连续）。

解题步骤

1. 确认条件事件 A 的形式，计算 $P(A)$ 。
2. 计算期望 $E[XI_A]$ 。若 X 连续，则转化为积分 $\int_A x f_X(x) dx$ 。
3. 利用公式 (9-1) 作除法求得结果。
4. 若分布具有无记忆性（如指数分布），可结合无记忆性直接简化计算。

易错点

- 混淆 $E(X|A)$ 与 $E(XI_A)$ ，前者是条件期望（除以了 $P(A)$ ），后者是乘积的期望。
- 在计算 $E[XI_A]$ 时，积分区域错误（应仅在 A 发生的区域积分）。

[Lecture 09_handout.pdf P19 例 2.1]

题目

设 $X \sim \mathcal{E}(\lambda)$, 对 $a > 0$, 证明 $E(X|X > a) = a + 1/\lambda$ 。

思路

利用公式 $E(X|A) = E[XI_A]/P(A)$, 其中 $A = \{X > a\}$ 。也可利用指数分布的无记忆性。

解答

法一（公式法）：

$$P(X > a) = e^{-\lambda a}$$

$$E[XI_{\{X > a\}}] = \int_a^{\infty} x \lambda e^{-\lambda x} dx$$

利用分部积分计算上述积分, 得 $\int_a^{\infty} x \lambda e^{-\lambda x} dx = (a + \frac{1}{\lambda})e^{-\lambda a}$ 。

$$E(X|X > a) = \frac{(a + 1/\lambda)e^{-\lambda a}}{e^{-\lambda a}} = a + \frac{1}{\lambda}$$

法二（无记忆性）：指数分布具有无记忆性, 在 $X > a$ 的条件下, $X - a$ 依然服从 $\mathcal{E}(\lambda)$ 。

$$E(X|X > a) = a + E(X - a|X > a) = a + E(X) = a + \frac{1}{\lambda}$$

技巧

对于指数分布等具有无记忆性的分布, 求形如 $E(X|X > a)$ 时, 直接使用无记忆性可秒解。

2. 全期望定理 重点

定义 设 $A_1, \dots, A_n$ 构成样本空间 Ω 的一个分割, 且 $P(A_i) > 0$, 则:

$$E(X) = \sum_{i=1}^n P(A_i)E(X|A_i) \quad (9-2)$$

原理与推导: 由全概率公式 $p_X(x) = \sum p_{X|A_i}(x)P(A_i)$, 两边同乘 x 求期望 (或积分), 交换求和号即可得证。该定理是重期望法则在事件条件下的特例。

解题步骤

1. 寻找样本空间的一个合理分割 $A_1, \dots, A_n$ (常对应某种分类或第一步的随机结果)。
2. 分别计算在每个分割下 X 的条件期望 $E(X|A_i)$ 。
3. 按各分割发生的概率 $P(A_i)$ 作加权平均。

[Lecture 09_handout.pdf P33-34 例 2.5]

题目

密室逃脱问题。玩家等可能地选定三个门之一: 第一个门走 3 小时到出口; 第二个门走 5 小时回原地; 第三个门走 7 小时回原地。求到达出口平均要花多长时间?

思路

设 X 为到达出口总时数, Y 为最初选定的门编号。 Y 构成样本空间分割, 利用全期望定理 $E(X) = \sum E(X|Y = i)P(Y = i)$ 。

解答

已知 $P(Y = 1) = P(Y = 2) = P(Y = 3) = 1/3$ 。条件期望为: $E(X|Y = 1) = 3$ $E(X|Y = 2) = 5 + E(X)$ (走 5 小时回原地, 状态重置) $E(X|Y = 3) = 7 + E(X)$ 代入全期望公式:

$$E(X) = \frac{1}{3} \times 3 + \frac{1}{3} \times (5 + E(X)) + \frac{1}{3} \times (7 + E(X))$$

$$E(X) = 5 + \frac{2}{3}E(X)$$

解得 $E(X) = 15$ 。

技巧

遇到“回原地”或“重置”的递归期望问题, 必用全期望定理构建关于 $E(X)$ 的方程求解。

二、条件在随机变量上的条件期望 $E(X|Y)$ 高频1. $E(X|Y)$ 的定义与计算

定义 设 X, Y 是随机向量, $E(X)$ 存在。给定 $Y = y$ 时, X 的条件期望定义为 $m(y) = E(X|Y = y)$ 。

- 离散型: $E(X|Y = y) = \sum_i x_i P(X = x_i|Y = y)$
- 连续型: $E(X|Y = y) = \int_{-\infty}^{\infty} x f_{X|Y}(x|y) dx$

由于 y 的取值随 Y 随机变化, $m(Y) = E(X|Y = y)|_{y=Y}$ 也是一个随机变量, 称其为给定 Y 时 X 的条件期望, 记作 $E(X|Y)$ 。

解题步骤

1. 视 $Y = y$ 为常数, 求条件分布 $P(X|Y = y)$ 或 $f_{X|Y}(x|y)$ 。
2. 在条件分布下求期望, 得到关于 y 的函数 $m(y)$ 。
3. 将表达式中的 y 替换为随机变量 Y , 即得 $E(X|Y)$ 。

易错点

- 误认为 $E(X|Y)$ 是一个确定的实数。它是以 Y 为自变量的随机变量函数。
- 忘记最后一步将 y 替换为 Y 。

[Lecture 09_handout.pdf P26, 30 例 2.4]

题目

设 $(X, Y) \sim \mathcal{N}(\mu_1, \mu_2, \sigma_1^2, \sigma_2^2, \rho)$, 求 $E(X|Y)$ 。

思路

利用二元正态分布的条件分布性质, 先求 $X|Y = y$ 的分布, 再求期望, 最后替换 y 。

解答

对于二元正态分布, 给定 $Y = y$ 时, X 的条件分布仍为正态:

$$X|Y = y \sim \mathcal{N}\left(\mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2), (1 - \rho^2)\sigma_1^2\right)$$

其期望为:

$$E(X|Y = y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(y - \mu_2)$$

将 y 替换为 Y , 得:

$$E(X|Y) = \mu_1 + \rho \frac{\sigma_1}{\sigma_2}(Y - \mu_2)$$

技巧

二元正态分布的条件期望是 Y 的线性函数, 直接记住公式可大幅节省推导时间。

2. 重期望法则 必背

定义 设 X, Y 是随机变量, 且期望存在, 则:

$$E[E(X|Y)] = E(X) \quad (9-3)$$

原理与推导: $E[E(X|Y)] = E[m(Y)] = \sum_y m(y)P(Y = y) = \sum_y E(X|Y = y)P(Y = y) = E(X)$ 。
此法则是全期望定理在随机变量条件下的推广。

解题步骤

1. 当直接求 $E(X)$ 困难, 但给定 Y 后 X 的规律明显时, 先求 $E(X|Y)$ 。
2. 对 $E(X|Y)$ 再求一次关于 Y 的无条件期望。

[Lecture 09_handout.pdf P35-37 例 2.6]

题目

设环境指标 $Y \sim \Gamma(\alpha, \beta)$, 已知 $Y = y$ 时, 软件寿命 $X \sim \mathcal{E}(y)$ 。计算 $E(X)$ 。

思路

直接求 X 的边缘分布较难, 利用重期望法则 $E(X) = E[E(X|Y)]$, 先求 $E(X|Y)$ 。

解答

给定 $Y = y$, $X \sim \mathcal{E}(y)$, 指数分布期望为 $1/y$, 故:

$$E(X|Y) = \frac{1}{Y}$$

由重期望法则:

$$E(X) = E[E(X|Y)] = E\left[\frac{1}{Y}\right] = \int_0^\infty \frac{1}{y} f_Y(y) dy$$

代入 Gamma 分布密度 $f_Y(y) = \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-1} e^{-\beta y}$:

$$E(X) = \int_0^\infty \frac{\beta^\alpha}{\Gamma(\alpha)} y^{\alpha-2} e^{-\beta y} dy$$

凑 Gamma 函数积分: 当 $\alpha > 1$ 时, 积分为 $\frac{\beta^\alpha}{\Gamma(\alpha)} \frac{\Gamma(\alpha-1)}{\beta^{\alpha-1}} = \frac{\beta}{\alpha-1}$ 。当 $0 < \alpha \leq 1$ 时, 积分发散, $E(X) = \infty$ 。

技巧

遇到“参数本身也是随机变量”的复合分布求期望, 必用重期望法则 $E(X) = E[E(X|Y)]$ 。

3. $E(X|Y)$ 的性质 重点

原理与推导: 条件期望 $E(\cdot|Y)$ 在给定 Y 时相当于普通的期望算子, 因此具有期望的线性、单调性等性质, 同时具有独特的“提取已知变量”性质。

1. 线性性: $E(c + \sum c_i X_i | Y) = c + \sum c_i E(X_i | Y)$
2. 单调性: 若 $X_1 \leq X_2$, 则 $E(X_1 | Y) \leq E(X_2 | Y)$
3. 提取已知变量: $E(h(Y)g(X) | Y) = h(Y)E(g(X) | Y)$
4. 独立性: 若 X, Y 独立, $E(g(X) | Y) = E(g(X))$
5. 重期望推广: $E[E(g(X) | Y)] = E(g(X))$
6. 正交性: 若 $E(X^2) < \infty, E(h^2(Y)) < \infty$, 则 $E[(X - E(X|Y))h(Y)] = 0$

易错点

- 在 $E(h(Y)g(X) | Y)$ 中错误地将 $h(Y)$ 留在期望算子内。给定 Y 时 $h(Y)$ 应视为常数提出。
- 误用独立性性质, 注意 $E(X|Y) = E(X)$ 的充要条件是 X 与 Y 独立 (对于一般情况不成立, 仅独立时成立)。

[Lecture 09_handout.pdf P29 例 2.3]

题目

设 X, Y 独立同分布, 且 $X \sim P(\lambda)$, 求 $E(X + Y | X)$ 和 $E(X | X + Y)$ 。

思路

利用条件期望的线性性与独立性性质。求 $E(X|X+Y)$ 时利用对称性。

解答

(1) 求 $E(X+Y|X)$:

$$E(X+Y|X) = E(X|X) + E(Y|X)$$

因为 X, Y 独立, $E(Y|X) = E(Y) = \lambda$ 。而 $E(X|X) = X$ 。

$$E(X+Y|X) = X + \lambda$$

(2) 求 $E(X|X+Y)$: 设 $S = X+Y$ 。由对称性, $E(X|S) = E(Y|S)$ 。又因为 $E(X+Y|S) = E(S|S) = S$, 所以:

$$E(X|S) + E(Y|S) = S \implies 2E(X|S) = S$$

$$E(X|X+Y) = \frac{X+Y}{2}$$

技巧

当两独立同分布随机变量求条件期望时, 充分利用对称性 $E(X|X+Y) = E(Y|X+Y)$ 可直接得出结果。

4. 最佳预测问题 高频

定义 设 $E(X^2) < \infty$, 以均方误差为标准, $E(X|Y)$ 是 X 的最佳预测。即对任意实函数 g , 有:

$$E[(X - E(X|Y))^2] \leq E[(X - g(Y))^2] \quad (9-4)$$

等号成立当且仅当 $g(Y) = E(X|Y)$ a.s.

原理与推导: 令 $m(Y) = E(X|Y)$, $h(Y) = m(Y) - g(Y)$ 。 $E[(X - g(Y))^2] = E[(X - m(Y) + h(Y))^2] = E[(X - m(Y))^2] + E[h^2(Y)] + 2E[(X - m(Y))h(Y)]$ 。由条件期望的正交性, 交叉项 $E[(X - m(Y))h(Y)] = 0$ 。故上式 $= E[(X - m(Y))^2] + E[h^2(Y)] \geq E[(X - m(Y))^2]$ 。

解题步骤

1. 遇到“求最佳预测/最小均方误差预测”问题, 直接回答 $E(X|Y)$ 。
2. 若要求最佳线性预测, 则需利用公式 $\hat{X} = E(X) + \frac{\text{Cov}(X,Y)}{\text{Var}(Y)}(Y - E(Y))$ 。对于二元正态分布, 最佳预测等于最佳线性预测。

三、条件方差 重点

1. 条件方差的定义与全方差法则

定义 给定 Y 时 X 的条件方差定义为:

$$\text{var}(X|Y) = E[(X - E(X|Y))^2|Y] \quad (9-5)$$

类似于普通方差，条件方差也有简化计算公式： $\text{var}(X|Y) = E(X^2|Y) - [E(X|Y)]^2$ 。

原理与推导（全方差法则）：无条件方差可通过条件方差与条件期望的方差分解求得：

$$\text{var}(X) = E[\text{var}(X|Y)] + \text{var}(E(X|Y)) \quad (9-6)$$

推导： $\text{var}(X) = E(X^2) - [E(X)]^2 = E[E(X^2|Y)] - [E(E(X|Y))]^2$ 。将 $E(X^2|Y) = \text{var}(X|Y) + [E(X|Y)]^2$ 代入上式第一项： $E[\text{var}(X|Y) + [E(X|Y)]^2] - [E(E(X|Y))]^2 = E[\text{var}(X|Y)] + \text{var}(E(X|Y))$ 。

解题步骤

1. 寻找合适的条件变量 Y 。
2. 计算 $E(X|Y)$ ，进而求其方差 $\text{var}(E(X|Y))$ 。
3. 计算 $\text{var}(X|Y)$ ，进而求其期望 $E[\text{var}(X|Y)]$ 。
4. 两者相加得到 $\text{var}(X)$ 。

易错点

- 混淆 $E[\text{var}(X|Y)]$ 与 $\text{var}(X|Y)$ ，前者是对随机变量 $\text{var}(X|Y)$ 求期望得实数，后者是 Y 的函数。
- 忘记全方差公式中的第二项 $\text{var}(E(X|Y))$ 。

[Lecture 09_handout.pdf P49 例 3.1]

题目

设 Y 为选课人数， X_i 为第 i 位同学 5 年内写论文篇数， X_i 独立同分布且与 Y 独立。 $X = X_1 + \cdots + X_Y$ 。已知 $E(X_1), E(Y), \text{var}(X_1), \text{var}(Y)$ ，求 $E(X)$ 和 $\text{var}(X)$ 。

思路

随机个随机变量之和。利用重期望法则求 $E(X)$ ，利用全方差法则求 $\text{var}(X)$ ，条件均选为 Y 。

解答

给定 $Y = n$, X 是 n 个独立同分布变量的和。

$$E(X|Y = n) = nE(X_1) \implies E(X|Y) = YE(X_1)$$

$$\text{var}(X|Y = n) = n\text{var}(X_1) \implies \text{var}(X|Y) = Y\text{var}(X_1)$$

求期望：

$$E(X) = E[E(X|Y)] = E[YE(X_1)] = E(Y)E(X_1)$$

求方差（全方差法则）：

$$\begin{aligned}\text{var}(X) &= E[\text{var}(X|Y)] + \text{var}(E(X|Y)) \\ &= E[Y\text{var}(X_1)] + \text{var}(YE(X_1)) \\ &= E(Y)\text{var}(X_1) + [E(X_1)]^2\text{var}(Y)\end{aligned}$$

技巧

处理“随机多个独立同分布随机变量之和”（如 $S = \sum_{i=1}^N X_i$ ）时，必用全方差公式，结论 $\text{var}(S) = E(N)\text{Var}(X) + [E(X)]^2\text{Var}(N)$ 可作为公式直接记忆。

本章小结

- **本章知识关系：**本章从条件概率出发，将条件从事件 A 推广到随机变量 Y ，建立了条件期望 $E(X|Y)$ 的概念。重期望法则和全方差法则打通了条件数字特征与无条件数字特征之间的桥梁，使得复杂分布的期望与方差可以通过引入隐含变量（条件）分步求解。条件期望的“最佳预测”性质则为后续统计回归分析奠定了理论基础。
- **本章核心结论：** $E(X|Y)$ 是随机变量； $E[E(X|Y)] = E(X)$ ； $\text{var}(X) = E[\text{var}(X|Y)] + \text{var}(E(X|Y))$ ； $E(X|Y)$ 是 X 的最小均方误差预测。
- **必背公式：**
 - $E(X|A) = \frac{E[XI_A]}{P(A)}$
 - $E(X) = \sum P(A_i)E(X|A_i)$
 - $E[E(X|Y)] = E(X)$
 - $E(h(Y)g(X)|Y) = h(Y)E(g(X)|Y)$
 - $\text{var}(X|Y) = E(X^2|Y) - [E(X|Y)]^2$
 - $\text{var}(X) = E[\text{var}(X|Y)] + \text{var}(E(X|Y))$
- **记忆：**期望重期望等于期望，全方差等于条件方差的期望加条件期望的方差；算条件期望时， Y 当常数算完再换回随机变量。